

ANALISIS DATA PEMBANGUNAN WILAYAH MENGUNAKAN R

Disusun Oleh:

Diaz Ramaananta Harahap	J0403251048
Nashira Salima Firmansyah	J0403251056
Dede Risma Komalasari	J0403251049
Zalfa Nazla Azkiya	J0403251037
Fahrizal Azis	J0403251151
Muhamad Akbar Zainuri	J0403251008



MATA KULIAH PROBABILITAS & STATISTIKA
PROGRAM STUDI TEKNOLOGI REKAYASA PERANGKAT LUNAK
SEKOLAH VOKASI

INSTITUT PERTANIAN BOGOR

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pembangunan wilayah adalah sebuah proses yang bertujuan untuk meningkatkan kesejahteraan masyarakat. Untuk mengetahui bagaimana suatu pembangunan wilayah di suatu daerah berhasil diperlukan indikator yang dapat menggambarkan keadaan masyarakat di wilayah tersebut dengan jelas, seperti angka kemiskinan, pengangguran, Produk Domestik Regional Bruto (PDRB), serta indeks pembangunan Manusia (IPM).

Oleh karena itu, diperlukan analisis data untuk mengolah informasi yang ada agar dapat memberikan gambaran tentang kondisi pembangunan di suatu wilayah. Berdasarkan kebutuhan tersebut, proyek ini bertujuan untuk menganalisis data pembangunan wilayah di seluruh Indonesia dengan mengimplementasikan bahasa pemrograman R. Melalui proyek akhir ini, mahasiswa diharapkan dapat meningkatkan keterampilan mereka dalam mengolah, menganalisis, dan menginterpretasikan data terkait pembangunan daerah dengan memanfaatkan bahasa pemrograman R.

1.2 Tujuan

Proyek ini bertujuan untuk menganalisis data mengenai pembangunan wilayah di Indonesia dengan memanfaatkan bahasa pemrograman R. Analisis dilakukan untuk mengenali ciri-ciri data, memahami hubungan di antara indikator pembangunan, serta mengungkap faktor-faktor yang memengaruhi tingkat perkembangan suatu daerah. Di samping itu, proyek ini bertujuan untuk mengaplikasikan konsep statistika dan analisis data dalam menyelesaikan masalah yang ada serta menyajikan hasil analisis dengan cara yang terstruktur dan informatif.

BAB II

METODOLOGI

2.1 Dataset

Dataset adalah kumpulan data terstruktur yang digunakan untuk berbagai keperluan, seperti analisis, penelitian, atau pengolahan informasi lainnya. Di dalam sebuah dataset, terdapat sejumlah variabel yang disusun dalam bentuk tabel. Setiap kolom mewakili atribut tertentu, sementara setiap baris menggambarkan entitas atau observasi yang berbeda. Dataset menjadi komponen penting dalam pengolahan data, membantu menghasilkan informasi yang lebih bermakna dan bermanfaat.

Data yang digunakan dalam analisis ini adalah dataset skor pembangunan wilayah tingkat Kabupaten/Kota di Indonesia. Secara keseluruhan, dataset ini mencakup observasi 2.500 baris kabupaten/kota dengan 13 kolom variabel, yang berada dalam rentang waktu lima tahun, yaitu dari tahun 2020 hingga 2024. Berikut adalah rincian variabel-variabel yang telah dikelompokkan menjadi beberapa kategori:

1. Variabel Identitas Data : wilayah, provinsi, dan tahun.
2. Variabel Ekonomi : pdrb_perkapita, kemiskinan, dan pengangguran.
3. Variabel Pembangunan Manusia : ipm, harapan_hidup, rata_lama_sekolah.
4. Variabel Infrastruktur : akses_internet, jalan_baik, air_bersih.
5. Variabel Metadata : catatan_data.

Dataset pembangunan wilayah tersebut berbentuk dokumen .csv. Dokumen ini bisa diunduh melalui <https://pembangunanwilayahmissingoutlier.tiiny.site> untuk melihat dataset secara keseluruhan.

2.2 Tools Yang Digunakan

Dalam melakukan analisis data ini, digunakan perangkat lunak Rstudio dan library ggplot2 untuk menghasilkan informasi yang terstruktur dan akurat tentang pembangunan wilayah di Indonesia. Berikut adalah rincian tools yang digunakan:

1. **Dataset format .csv:** Digunakan sebagai format penyimpanan data mentah yang menjadi objek utama analisis.
2. **Bahasa Pemrograman R:** R digunakan sebagai bahasa pemrograman utama untuk komputasi statistik dan analisis data. Bahasa ini dipilih karena memiliki kemampuan yang kuat dalam melakukan manipulasi data, serta menyediakan berbagai paket statistik yang mumpuni untuk melakukan analisis deskriptif maupun inferensial pada dataset.
3. **RStudio:** RStudio digunakan sebagai *Integrated Development Environment (IDE)* atau lingkungan pengembangan terintegrasi untuk menulis dan mengeksekusi kode R. RStudio mempermudah manajemen proyek, pemantauan variabel, penanganan error melalui antarmuka yang interaktif, serta mendukung penyusunan laporan menggunakan R Markdown.
4. **Library ggplot2:** Library ggplot2 digunakan untuk memenuhi kebutuhan visualisasi data. Library ini memungkinkan pembuatan grafik secara modular. Di dalam proyek ini, ggplot2 digunakan untuk menyajikan tren indikator pembangunan, mengidentifikasi sebaran data, serta memberikan visualisasi perbandingan kondisi antarwilayah secara informatif.

2.3 Metode Analisis

Analisis data dilakukan menggunakan bahasa pemrograman R untuk memperoleh gambaran mengenai kondisi pembangunan wilayah di Indonesia. Tahapan analisis yang dilakukan adalah sebagai berikut:

1. **Pengumpulan Data:** Data yang digunakan merupakan data indikator pembangunan wilayah yang mencakup beberapa variabel pdrb_perkapita, kemiskinan, pengangguran, IPM, akses_internet, dll).
2. **Analisis Statistik Deskriptif:** Analisis statistik deskriptif dilakukan untuk menggambarkan karakteristik data melalui nilai minimum, nilai maksimum, rata-rata, median, standar deviasi, dan lain-lain.
3. **Analisis Missing Value:** Missing value dianalisis dengan menghitung jumlah dan persentase data yang hilang pada setiap variabel. Hasil analisis digunakan untuk menentukan metode penanganan yang sesuai.

4. **Analisis Outliers:** Deteksi outlier dilakukan menggunakan metode Interquartile Range (IQR). Suatu data dikatakan sebagai outlier apabila berada di luar batas.
5. **Visualisasi Data:** Visualisasi dilakukan untuk mempermudah interpretasi data menggunakan histogram, boxplot, scatter plot, dan heatmap korelasi.
6. **Analisis Korelasi:** Analisis korelasi digunakan untuk mengetahui hubungan antar indikator pembangunan wilayah. Kolerasi dihitung menggunakan koefisien korelasi pearson dengan rentang nilai $-1 \leq r \leq 1$. Nilai korelasi yang mendekati 1 menunjukkan hubungan positif yang kuat, sedangkan nilai yang mendekati -1 menunjukkan hubungan negatif yang kuat.

BAB III

HASIL DAN PEMBAHASAN

3.1 Statistika Deskriptif

Statistika deskriptif merupakan metode statistik yang digunakan untuk meringkas dan menggambarkan karakteristik utama dari suatu kumpulan data secara numerik. Analisis ini bertujuan untuk memberikan gambaran awal mengenai kondisi data pembangunan wilayah, khususnya terkait ukuran pemusatan data seperti mean dan median serta ukuran penyebaran data seperti standar deviasi, varians, dan rentang nilai.

Pada penelitian ini, analisis statistika deskriptif dilakukan terhadap seluruh variabel numerik pada dataset pembangunan wilayah menggunakan beberapa fungsi dalam bahasa pemrograman R seperti *summary()*, *mean()*, *median()*, *sd()*, *var()*, dan *quantile()*.

Tabel 3.1 Hasil Statistika Deskriptif

Variabel	Mean	SD	Keterangan
pdrb_perkapita	Tinggi	Paling besar	Penyebaran sangat tinggi
kemiskinan	13,72	Cukup besar	Terdapat variasi data
pengangguran	8	Besar	Indikasi data ekstrem
ipm	69–70	Relatif kecil	Distribusi stabil
harapan_hidup	69 tahun	Relatif kecil	Distribusi stabil
rata_lama_sekolah	9,5 tahun	Relatif kecil	Distribusi stabil

Berdasarkan hasil analisis, variabel *pdrb_perkapita* memiliki nilai rata-rata tertinggi dibandingkan variabel lainnya. Selain itu, variabel tersebut juga mempunyai standar deviasi terbesar yang menunjukkan bahwa terdapat perbedaan tingkat pendapatan yang cukup besar antar wilayah di Indonesia.

Variabel *kemiskinan* dan *pengangguran* juga menunjukkan penyebaran data yang cukup besar. Hal ini terlihat dari rentang nilai minimum dan maksimum yang jauh berbeda. Pada variabel

pengangguran, nilai maksimum bahkan jauh di atas rata-ratanya sehingga mengindikasikan adanya beberapa data ekstrem.

Sementara itu, variabel seperti *ipm*, *harapan_hidup*, dan *rata_lama_sekolah* memiliki nilai mean dan median yang relatif berdekatan. Kondisi tersebut menunjukkan bahwa distribusi data pada variabel pembangunan manusia cenderung lebih stabil dan tidak terlalu menyebar.

Perbedaan mean dan median yang cukup jauh pada beberapa variabel ekonomi memberikan indikasi awal bahwa data kemungkinan tidak berdistribusi normal serta terdapat outlier pada beberapa wilayah. Oleh karena itu, analisis lanjutan mengenai missing value dan outlier perlu dilakukan pada tahap berikutnya.

3.2 Missing Value

Missing value, atau data yang hilang, terjadi ketika salah satu kolom atau atribut dalam dataset tidak memiliki nilai. Hal ini bisa disebabkan oleh kesalahan pencatatan, keterbatasan teknis selama proses pengumpulan data, atau kondisi tertentu di mana data memang tidak tersedia. Misalnya, dalam analisis data pembangunan ini, jika data IPM hilang, sulit menyimpulkan tingkat pembangunan wilayah secara keseluruhan.

Pada penelitian ini, penanganan dilakukan terhadap baris data yang memiliki *missing value* dalam dataset pembangunan wilayah menggunakan bahasa pemrograman R, yang dimulai dengan mengukur terlebih dahulu seberapa besar pengaruhnya dalam data.

Tabel 3.2 Hasil Analisis *Missing Value*

Variabel	Missing Value	Persentase
pdrb_perkapita	25	1%
kemiskinan	24	0.96%
pengangguran	25	1%
IPM	25	1%
akses_internet	25	1%
jalan_baik	25	1%
Rata-Rata Persentase		0.45%

Berdasarkan hasil analisis, ditemukan *missing value* pada beberapa variabel seperti *pdrb_perkapita*, *kemiskinan*, *pengangguran*, *IPM*, *akses_internet*, dan *jalan_baik*. Keberadaan *missing value* ini dapat mempengaruhi hasil analisis statistik, salah satu contohnya adalah mengurangi jumlah observasi yang dapat di analisis.

Data yang memiliki nilai kosong tidak dapat digunakan secara langsung dalam berbagai metode statistik. Akibatnya, jumlah data yang tersedia untuk analisis menjadi berkurang sehingga informasi yang diperoleh menjadi kurang lengkap.

Untuk metode penanganan *missing value* itu sendiri, yang kami gunakan adalah penghapusan. Metode ini dipilih karena proporsi data yang hilang pada setiap variabel relatif kecil yaitu 1% dari total observasi, dimana tidak menyebabkan berkurangnya representativitas data secara signifikan, sehingga dampaknya terhadap analisis diperkirakan sangat kecil.

Alasan lainnya adalah, metode ini sederhana dan sangat efektif jika jumlah *missing value* kecil, misalnya 1-2% dari data. Namun, jika jumlah data yang hilang mencapai 30% atau lebih, metode ini beresiko mengurangi informasi penting dan tidak disarankan.

3.3 Outlier


Outliers adalah nilai yang berbeda secara signifikan dari sebagian besar data lainnya, sering kali muncul karena kesalahan pengukuran, variasi alami, atau anomali yang tidak terduga. *Outliers* dapat berdampak negatif pada analisis, seperti menggeser rata-rata. Oleh karena itu, deteksi dan penanganan *outliers* menjadi langkah penting yang harus dilakukan.

Pada penelitian ini, dataset pembangunan wilayah memiliki outlier pada sejumlah variabel, yaitu *pdrb_perkapita*, *kemiskinan*, dan *pengangguran*. Berikut penjabaran seberapa banyak outliers yang dimiliki setiap variabel tersebut.

Tabel 3.3 Hasil Analisis *Outliers*

Variabel	Jumlah Outliers
pdrb_perkapita	5
kemiskinan	5
pengangguran	5

Gambar 3.1 Boxplot Outlier



Tabel 3.4 Nilai-Nilai *Outliers* yang Terdeteksi

pdrb_perkapita	kemiskinan	pengangguran
1.012.449.971	45,95	33,19
1.087.231.959	47,69	34,90
1.472.419.961	53,50	36,68
1.474.832.345	58,41	36,74
1.774.545.027	67,53	47,04

Dalam analisis ini, metode deteksi *outliers* yang kami gunakan adalah **IQR**. Metode ini mengidentifikasi *outliers* dengan menghitung rentang antara kuartil pertama (Q1) dan kuartil ketiga (Q3). Nilai yang berada diluar rentang $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ dianggap sebagai *outliers*.

Nilai *outliers* juga memiliki dampak besar terhadap analisis statistik, salah satu contohnya adalah, *outliers* dapat menarik ukuran pemusatan data ke arah nilai ekstrem. Berikut tabel dampak nilai *outliers* yang sudah di analisis.

Tabel 3.5 Dampak *Outliers* terhadap Nilai Rata-Rata

Variabel	Mean Sebelum Penghapusan	Mean Setelah Penghapusan	Selisih
pdrb_perkapita	135.650.462	133.163.326	2.487.136
kemiskinan	13.72	13.64	0.08
pengangguran	8.05	7.99	0.06

Variabel *pdrb_perkapita* mengalami perubahan rata-rata terbesar setelah *outlier* dihapus, yaitu sebesar 2.487.136. Ini menunjukkan bahwa keberadaan beberapa daerah dengan nilai *pdrb_perkapita* yang sangat tinggi memberikan pengaruh yang cukup besar terhadap nilai rata-rata keseluruhan. Sementara itu, variabel kemiskinan dan pengangguran hanya mengalami perubahan rata-rata yang relatif kecil, sehingga pengaruh *outlier* terhadap kedua variabel tersebut tidak sebesar pada variabel *pdrb_perkapita*.

3.4 Visualisasi Data

Visualisasi data merupakan salah satu teknik analisis yang digunakan untuk menyajikan informasi dalam bentuk grafik sehingga pola, tren, serta karakteristik data dapat dipahami dengan lebih mudah. Pada penelitian ini, visualisasi dilakukan menggunakan library *ggplot2* pada bahasa pemrograman R untuk membantu proses interpretasi data pembangunan wilayah di Indonesia.

Beberapa jenis visualisasi yang digunakan meliputi histogram, boxplot, dan scatter plot. Histogram digunakan untuk melihat distribusi data pada variabel *ipm* dan *kemiskinan*, boxplot digunakan untuk mengidentifikasi keberadaan *outlier* pada variabel *pdrb_perkapita*, sedangkan scatter plot digunakan untuk mengamati hubungan antar variabel pembangunan wilayah.

Gambar 3.2 Histogram Nilai IPM