

# **ANALISIS DATA PEMBANGUNAN WILAYAH MENGUNAKAN R**

**Disusun Oleh:**

**Diaz Ramaananta Harahap    J0403251048**

**Nashira Salima Firmansyah    J0403251056**

**Dede Risma Komalasari        J0403251049**

**Zalfa Nazla Azkiya            J0403251037**

**Fahrizal Azis                    J0403251151**

**Muhamad Akbar Zainuri        J0403251008**

**MATA KULIAH PROBABILITAS & STATISTIKA  
PROGRAM STUDI TEKNOLOGI REKAYASA  
PERANGKAT LUNAK  
SEKOLAH VOKASI  
INSITUT PERTANIAN BOGOR**

**2026**

# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Pembangunan wilayah adalah sebuah proses yang bertujuan untuk meningkatkan kesejahteraan masyarakat. Untuk mengetahui bagaimana suatu pembangunan wilayah di suatu daerah berhasil diperlukan indikator yang dapat menggambarkan keadaan masyarakat di wilayah tersebut dengan jelas, seperti angka kemiskinan, pengangguran, Produk Domestik Regional Bruto (PDRB), serta indeks pembangunan Manusia (IPM).

Oleh karena itu, diperlukan analisis data untuk mengolah informasi yang ada agar dapat memberikan gambaran tentang kondisi pembangunan di suatu wilayah. Berdasarkan kebutuhan tersebut, proyek ini bertujuan untuk menganalisis data pembangunan wilayah di seluruh Indonesia dengan mengimplementasikan bahasa pemrograman R. Melalui proyek akhir ini, mahasiswa diharapkan dapat meningkatkan keterampilan mereka dalam mengolah, menganalisis, dan menginterpretasikan data terkait pembangunan daerah dengan memanfaatkan bahasa pemrograman R.

### **1.2 Tujuan**

Proyek ini bertujuan untuk menganalisis data mengenai pembangunan wilayah di Indonesia dengan memanfaatkan bahasa pemrograman R. Analisis dilakukan untuk mengenali ciri-ciri data, memahami hubungan di antara indikator pembangunan, serta mengungkap faktor-faktor yang memengaruhi tingkat perkembangan suatu daerah. Di samping itu, proyek ini bertujuan untuk mengaplikasikan konsep statistika dan analisis data dalam menyelesaikan masalah yang ada serta menyajikan hasil analisis dengan cara yang terstruktur dan informatif.

# **BAB II**

## **METODOLOGI**

### **2.1 Dataset**

Dataset adalah kumpulan data terstruktur yang digunakan untuk berbagai keperluan, seperti analisis, penelitian, atau pengolahan informasi lainnya. Di dalam sebuah dataset, terdapat sejumlah variabel yang disusun dalam bentuk tabel. Setiap kolom mewakili atribut tertentu, sementara setiap baris menggambarkan entitas atau observasi yang berbeda. Dataset menjadi komponen penting dalam pengolahan data, membantu menghasilkan informasi yang lebih bermakna dan bermanfaat.

Data yang digunakan dalam analisis ini adalah dataset skor pembangunan wilayah tingkat Kabupaten/Kota di Indonesia. Secara keseluruhan, dataset ini mencakup observasi 2.500 baris kabupaten/kota dengan 13 kolom variabel, yang berada dalam rentang waktu lima tahun, yaitu dari tahun 2020 hingga 2024. Berikut adalah rincian variabel-variabel yang telah dikelompokkan menjadi beberapa kategori:

1. Variabel Identitas Data : wilayah, provinsi, dan tahun.
2. Variabel Ekonomi : pdrb\_perkapita, kemiskinan, dan pengangguran.
3. Variabel Pembangunan Manusia : ipm, harapan\_hidup, rata\_lama\_sekolah.
4. Variabel Infrastruktur : akses\_internet, jalan\_baik, air\_bersih.
5. Variabel Metadata : catatan\_data.

Dataset pembangunan wilayah tersebut berbentuk dokumen .csv. Dokumen ini bisa diunduh melalui <https://pembangunanwilayahmissingoutlier.tiiny.site> untuk melihat dataset secara keseluruhan.

### **2.2 Tools Yang Digunakan**

Dalam melakukan analisis data ini, digunakan perangkat lunak Rstudio dan library ggplot2 untuk menghasilkan informasi yang terstruktur dan akurat tentang pembangunan wilayah di Indonesia. Berikut adalah rincian tools yang digunakan:

1. **Dataset format .csv:** Digunakan sebagai format penyimpanan data mentah yang menjadi objek utama analisis.
2. **Bahasa Pemrograman R:** R digunakan sebagai bahasa pemrograman utama untuk komputasi statistik dan analisis data. Bahasa ini dipilih karena memiliki kemampuan yang kuat dalam melakukan manipulasi data, serta menyediakan berbagai paket statistik yang mumpuni untuk melakukan analisis deskriptif maupun inferensial pada dataset.
3. **RStudio:** RStudio digunakan sebagai *Integrated Development Environment (IDE)* atau lingkungan pengembangan terintegrasi untuk menulis dan mengeksekusi kode R. RStudio mempermudah manajemen proyek, pemantauan variabel, penanganan error melalui antarmuka yang interaktif, serta mendukung penyusunan laporan menggunakan R Markdown.
4. **Library ggplot2:** Library ggplot2 digunakan untuk memenuhi kebutuhan visualisasi data. Library ini memungkinkan pembuatan grafik secara modular. Di dalam proyek ini, ggplot2 digunakan untuk menyajikan tren indikator pembangunan, mengidentifikasi sebaran data, serta memberikan visualisasi perbandingan kondisi antarwilayah secara informatif.

## 2.3 Metode Analisis

## BAB III

### HASIL DAN PEMBAHASAN

#### 3.1 Statistika Deskriptif

Statistika deskriptif merupakan metode statistik yang digunakan untuk meringkas dan menggambarkan karakteristik utama dari suatu kumpulan data secara numerik. Analisis ini bertujuan untuk memberikan gambaran awal mengenai kondisi data pembangunan wilayah, khususnya terkait ukuran pemusatan data seperti mean dan median serta ukuran penyebaran data seperti standar deviasi, varians, dan rentang nilai.

Pada penelitian ini, analisis statistika deskriptif dilakukan terhadap seluruh variabel numerik pada dataset pembangunan wilayah menggunakan beberapa fungsi dalam bahasa pemrograman R seperti *summary()*, *mean()*, *median()*, *sd()*, *var()*, dan *quantile()*.

**Tabel 3.1 Hasil Statistika Deskriptif**

| Variabel          | Mean      | SD            | Keterangan               |
|-------------------|-----------|---------------|--------------------------|
| pdrb_perkapita    | Tinggi    | Paling besar  | Penyebaran sangat tinggi |
| kemiskinan        | 13,72     | Cukup besar   | Terdapat variasi data    |
| pengangguran      | 8         | Besar         | Indikasi data ekstrem    |
| ipm               | 69–70     | Relatif kecil | Distribusi stabil        |
| harapan_hidup     | 69 tahun  | Relatif kecil | Distribusi stabil        |
| rata_lama_sekolah | 9,5 tahun | Relatif kecil | Distribusi stabil        |

Berdasarkan hasil analisis, variabel *pdrb\_perkapita* memiliki nilai rata-rata tertinggi dibandingkan variabel lainnya. Selain itu, variabel tersebut juga mempunyai standar deviasi terbesar yang menunjukkan bahwa terdapat perbedaan tingkat pendapatan yang cukup besar antar wilayah di Indonesia.

Variabel *kemiskinan* dan *pengangguran* juga menunjukkan penyebaran data yang cukup besar. Hal ini terlihat dari rentang nilai minimum dan maksimum yang jauh berbeda. Pada variabel

pengangguran, nilai maksimum bahkan jauh di atas rata-ratanya sehingga mengindikasikan adanya beberapa data ekstrem.

Sementara itu, variabel seperti *ipm*, *harapan\_hidup*, dan *rata\_lama\_sekolah* memiliki nilai mean dan median yang relatif berdekatan. Kondisi tersebut menunjukkan bahwa distribusi data pada variabel pembangunan manusia cenderung lebih stabil dan tidak terlalu menyebar.

Perbedaan mean dan median yang cukup jauh pada beberapa variabel ekonomi memberikan indikasi awal bahwa data kemungkinan tidak berdistribusi normal serta terdapat outlier pada beberapa wilayah. Oleh karena itu, analisis lanjutan mengenai missing value dan outlier perlu dilakukan pada tahap berikutnya.

### 3.2 Missing Value

*Missing value*, atau data yang hilang, terjadi ketika salah satu kolom atau atribut dalam data set tidak memiliki nilai. Hal ini bisa disebabkan oleh kesalahan pencatatan, keterbatasan teknis selama proses pengumpulan data, atau kondisi tertentu di mana data memang tidak tersedia. Misalnya, dalam analisis data pembangunan ini, jika data IPM hilang, sulit menyimpulkan tingkat pembangunan wilayah secara keseluruhan.

Salah satu metode penanganan *missing value* adalah dengan menghapus data. Metode ini sederhana dan sangat efektif jika jumlah *missing value* kecil, misalnya 1-2% dari data. Namun, jika jumlah data yang hilang mencapai 30% atau lebih, metode ini beresiko mengurangi informasi penting dan tidak disarankan.

Pada penelitian ini, penanganan dilakukan terhadap baris data yang memiliki *missing value* dalam dataset pembangunan wilayah menggunakan bahasa pemrograman R, yang dimulai dengan mengukur terlebih dahulu seberapa besar pengaruhnya dalam data.

**Tabel 3.2 Hasil Analisis *Missing Value***

| <b>Variabel</b>             | <b>Missing Value</b> | <b>Persentase</b> |
|-----------------------------|----------------------|-------------------|
| pdrb_perkapita              | 25                   | 1%                |
| kemiskinan                  | 24                   | 0.96%             |
| pengangguran                | 25                   | 1%                |
| IPM                         | 25                   | 1%                |
| akses_internet              | 25                   | 1%                |
| jalan_baik                  | 25                   | 1%                |
| <b>Rata-Rata Persentase</b> |                      | <b>0.45%</b>      |

Berdasarkan hasil analisis, penanganan *missing value* dilakukan dengan metode penghapusan. Metode ini dipilih karena proporsi data yang hilang pada setiap variabel relatif kecil yaitu 1% dari total observasi, dimana tidak menyebabkan berkurangnya representativitas data secara signifikan, sehingga dampaknya terhadap analisis diperkirakan sangat kecil.

### **3.3 Outlier**

### **3.4 Visualisasi**

### **3.5 Distribusi Data**

### **3.6 Korelasi**

### **3.7 Interpretasi**

## **BAB IV**

### **KESIMPULAN**

**4.1 Kesimpulan Utama**

**4.2 Insight**

**4.3 Saran**

# LAMPIRAN

## 5.1 Script R

## 5.2 Output Tambahan