

ANALISIS DATA PEMBANGUNAN WILAYAH MENGGUNAKAN R

Disusun Oleh:

Diaz Ramaananta Harahap	J0403251048
Nashira Salima Firmansyah	J0403251056
Dede Risma Komalasari	J0403251049
Zalfa Nazla Azkiya	J0403251037
Fahrizal Azis	J0403251151
Muhamad Akbar Zainuri	J0403251008



MATA KULIAH PROBABILITAS & STATISTIKA

PROGRAM STUDI TEKNOLOGI REKAYASA PERANGKAT LUNAK

SEKOLAH VOKASI

INSTITUT PERTANIAN BOGOR

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pembangunan wilayah adalah sebuah proses yang bertujuan untuk meningkatkan kesejahteraan masyarakat. Untuk mengetahui bagaimana suatu pembangunan wilayah di suatu daerah berhasil diperlukan indikator yang dapat menggambarkan keadaan masyarakat di wilayah tersebut dengan jelas, seperti angka kemiskinan, pengangguran, Produk Domestik Regional Bruto (PDRB), serta indeks pembangunan Manusia (IPM).

Oleh karena itu, diperlukan analisis data untuk mengolah informasi yang ada agar dapat memberikan gambaran tentang kondisi pembangunan di suatu wilayah. Berdasarkan kebutuhan tersebut, proyek ini bertujuan untuk menganalisis data pembangunan wilayah di seluruh Indonesia dengan mengimplementasikan bahasa pemrograman R. Melalui proyek akhir ini, mahasiswa diharapkan dapat meningkatkan keterampilan mereka dalam mengolah, menganalisis, dan menginterpretasikan data terkait pembangunan daerah dengan memanfaatkan bahasa pemrograman R.

1.2 Tujuan

Proyek ini bertujuan untuk menganalisis data mengenai pembangunan wilayah di Indonesia dengan memanfaatkan bahasa pemrograman R. Analisis dilakukan untuk mengenali ciri-ciri data, memahami hubungan di antara indikator pembangunan, serta mengungkap faktor-faktor yang memengaruhi tingkat perkembangan suatu daerah. Di samping itu, proyek ini bertujuan untuk mengaplikasikan konsep statistika dan analisis data dalam menyelesaikan masalah yang ada serta menyajikan hasil analisis dengan cara yang terstruktur dan informatif.

BAB II

METODOLOGI

2.1 Dataset

Dataset adalah kumpulan data terstruktur yang digunakan untuk berbagai keperluan, seperti analisis, penelitian, atau pengolahan informasi lainnya. Di dalam sebuah dataset, terdapat sejumlah variabel yang disusun dalam bentuk tabel. Setiap kolom mewakili atribut tertentu, sementara setiap baris menggambarkan entitas atau observasi yang berbeda. Dataset menjadi komponen penting dalam pengolahan data, membantu menghasilkan informasi yang lebih bermakna dan bermanfaat.

Data yang digunakan dalam analisis ini adalah dataset skor pembangunan wilayah tingkat Kabupaten/Kota di Indonesia. Secara keseluruhan, dataset ini mencakup observasi 2.500 baris kabupaten/kota dengan 13 kolom variabel, yang berada dalam rentang waktu lima tahun, yaitu dari tahun 2020 hingga 2024. Berikut adalah rincian variabel-variabel yang telah dikelompokkan menjadi beberapa kategori:

1. Variabel Identitas Data : wilayah, provinsi, dan tahun.
2. Variabel Ekonomi : pdrb_perkapita, kemiskinan, dan pengangguran.
3. Variabel Pembangunan Manusia : ipm, harapan_hidup, rata_lama_sekolah.
4. Variabel Infrastruktur : akses_internet, jalan_baik, air_bersih.
5. Variabel Metadata : catatan_data.

Dataset pembangunan wilayah tersebut berbentuk dokumen .csv. Dokumen ini bisa diunduh melalui <https://pembangunanwilayahmissingoutlier.tiiny.site> untuk melihat dataset secara keseluruhan.

2.2 Tools Yang Digunakan

Dalam melakukan analisis data ini, digunakan perangkat lunak Rstudio dan library ggplot2 untuk menghasilkan informasi yang terstruktur dan akurat tentang pembangunan wilayah di Indonesia. Berikut adalah rincian tools yang digunakan:

1. **Dataset format .csv:** Digunakan sebagai format penyimpanan data mentah yang menjadi objek utama analisis.
2. **Bahasa Pemrograman R:** R digunakan sebagai bahasa pemrograman utama untuk komputasi statistik dan analisis data. Bahasa ini dipilih karena memiliki kemampuan yang kuat dalam melakukan manipulasi data, serta menyediakan berbagai paket statistik yang mumpuni untuk melakukan analisis deskriptif maupun inferensial pada dataset.
3. **RStudio:** RStudio digunakan sebagai *Integrated Development Environment (IDE)* atau lingkungan pengembangan terintegrasi untuk menulis dan mengeksekusi kode R. RStudio mempermudah manajemen proyek, pemantauan variabel, penanganan error melalui antarmuka yang interaktif, serta mendukung penyusunan laporan menggunakan R Markdown.
4. **Library ggplot2:** Library ggplot2 digunakan untuk memenuhi kebutuhan visualisasi data. Library ini memungkinkan pembuatan grafik secara modular. Di dalam proyek ini, ggplot2 digunakan untuk menyajikan tren indikator pembangunan, mengidentifikasi sebaran data, serta memberikan visualisasi perbandingan kondisi antarwilayah secara informatif.

2.3 Metode Analisis

BAB III

HASIL DAN PEMBAHASAN

3.1 Statistika Deskriptif

Statistika deskriptif merupakan metode statistik yang digunakan untuk meringkas dan menggambarkan karakteristik utama dari suatu kumpulan data secara numerik. Analisis ini bertujuan untuk memberikan gambaran awal mengenai kondisi data pembangunan wilayah, khususnya terkait ukuran pemusatan data seperti mean dan median serta ukuran penyebaran data seperti standar deviasi, varians, dan rentang nilai.

Pada penelitian ini, analisis statistika deskriptif dilakukan terhadap seluruh variabel numerik pada dataset pembangunan wilayah menggunakan beberapa fungsi dalam bahasa pemrograman R seperti *summary()*, *mean()*, *median()*, *sd()*, *var()*, dan *quantile()*.

Tabel 3.1 Hasil Statistika Deskriptif

Variabel	Mean	SD	Keterangan
pdrb_perkapita	Tinggi	Paling besar	Penyebaran sangat tinggi
kemiskinan	13,72	Cukup besar	Terdapat variasi data
pengangguran	8	Besar	Indikasi data ekstrem
ipm	69–70	Relatif kecil	Distribusi stabil
harapan_hidup	69 tahun	Relatif kecil	Distribusi stabil
rata_lama_sekolah	9,5 tahun	Relatif kecil	Distribusi stabil

Berdasarkan hasil analisis, variabel *pdrb_perkapita* memiliki nilai rata-rata tertinggi dibandingkan variabel lainnya. Selain itu, variabel tersebut juga mempunyai standar deviasi terbesar yang menunjukkan bahwa terdapat perbedaan tingkat pendapatan yang cukup besar antar wilayah di Indonesia.

Variabel *kemiskinan* dan *pengangguran* juga menunjukkan penyebaran data yang cukup besar. Hal ini terlihat dari rentang nilai minimum dan maksimum yang jauh berbeda. Pada variabel

pengangguran, nilai maksimum bahkan jauh di atas rata-ratanya sehingga mengindikasikan adanya beberapa data ekstrem.

Sementara itu, variabel seperti *ipm*, *harapan_hidup*, dan *rata_lama_sekolah* memiliki nilai mean dan median yang relatif berdekatan. Kondisi tersebut menunjukkan bahwa distribusi data pada variabel pembangunan manusia cenderung lebih stabil dan tidak terlalu menyebar.

Perbedaan mean dan median yang cukup jauh pada beberapa variabel ekonomi memberikan indikasi awal bahwa data kemungkinan tidak berdistribusi normal serta terdapat outlier pada beberapa wilayah. Oleh karena itu, analisis lanjutan mengenai missing value dan outlier perlu dilakukan pada tahap berikutnya.

3.2 Missing Value

Missing value, atau data yang hilang, terjadi ketika salah satu kolom atau atribut dalam data set tidak memiliki nilai. Hal ini bisa disebabkan oleh kesalahan pencatatan, keterbatasan teknis selama proses pengumpulan data, atau kondisi tertentu di mana data memang tidak tersedia. Misalnya, dalam analisis data pembangunan ini, jika data IPM hilang, sulit menyimpulkan tingkat pembangunan wilayah secara keseluruhan.

Salah satu metode penanganan *missing value* adalah dengan menghapus data. Metode ini sederhana dan sangat efektif jika jumlah *missing value* kecil, misalnya 1-2% dari data. Namun, jika jumlah data yang hilang mencapai 30% atau lebih, metode ini beresiko mengurangi informasi penting dan tidak disarankan.

Pada penelitian ini, penanganan dilakukan terhadap baris data yang memiliki *missing value* dalam dataset pembangunan wilayah menggunakan bahasa pemrograman R, yang dimulai dengan mengukur terlebih dahulu seberapa besar pengaruhnya dalam data.

Tabel 3.2 Hasil Analisis *Missing Value*

Variabel	Missing Value	Persentase
pdrb_perkapita	25	1%
kemiskinan	24	0.96%
pengangguran	25	1%
IPM	25	1%
akses_internet	25	1%
jalan_baik	25	1%
Rata-Rata Persentase		0.45%

Berdasarkan hasil analisis, penanganan *missing value* dilakukan dengan metode penghapusan. Metode ini dipilih karena proporsi data yang hilang pada setiap variabel relatif kecil yaitu 1% dari total observasi, dimana tidak menyebabkan berkurangnya representativitas data secara signifikan, sehingga dampaknya terhadap analisis diperkirakan sangat kecil.

3.3 Outlier

3.4 Visualisasi

3.5 Distribusi Data

3.6 Korelasi

Analisis korelasi merupakan metode statistik yang digunakan untuk mengetahui hubungan antar variabel dalam suatu dataset. Pada penelitian ini, analisis korelasi dilakukan menggunakan metode *Pearson* untuk mengukur kekuatan serta arah hubungan linear antar variabel pembangunan wilayah.

Variabel yang dianalisis meliputi *pdrb_perkapita*, *kemiskinan*, *pengangguran*, *ipm*, *harapan_hidup*, *rata_lama_sekolah*, dan *akses_internet*. Hasil analisis korelasi ditampilkan dalam bentuk ringkasan berikut.

Tabel 3.6 Hasil Analisis Korelasi

Variabel 1	Variabel 2	Nilai Korelasi	Keterangan
pdrb_perkapita	kemiskinan	-0,0048	Sangat lemah (negatif)
pengangguran	pdrb_perkapita	-0,0323	Sangat lemah (negatif)
ipm	pdrb_perkapita	0,0111	Sangat lemah (positif)
harapan_hidup	pdrb_perkapita	0,0125	Sangat lemah (positif)
akses_internet	kemiskinan	-0,0309	Sangat lemah (negatif)
akses_internet	ipm	0,0020	Sangat lemah (positif)

Berdasarkan hasil analisis, seluruh nilai korelasi berada sangat dekat dengan nol, yaitu dalam rentang sekitar -0,03 hingga 0,01. Hal ini menunjukkan bahwa hubungan linear antar variabel dalam dataset pembangunan wilayah sangat lemah.

Tidak adanya korelasi yang kuat mengindikasikan bahwa variabel-variabel tersebut tidak memiliki hubungan linear yang signifikan dan kemungkinan dipengaruhi oleh faktor lain di luar model yang digunakan.

3.7 Interpretasi

BAB IV

KESIMPULAN

4.1 Kesimpulan Utama

Berdasarkan hasil analisis data pembangunan wilayah menggunakan bahasa pemrograman R, dapat disimpulkan bahwa dataset memiliki kualitas yang baik dengan tingkat *missing value* yang sangat rendah, yaitu sekitar 0,45% dari keseluruhan data. Penanganan *missing value* dilakukan dengan metode penghapusan karena proporsinya relatif kecil dan tidak memengaruhi representativitas data secara signifikan.

Analisis statistika deskriptif menunjukkan bahwa variabel ekonomi memiliki tingkat variasi yang lebih tinggi dibandingkan variabel pembangunan manusia. Selain itu, analisis *outlier* menunjukkan adanya beberapa data ekstrem pada variabel PDRB per kapita, kemiskinan, dan pengangguran.

Hasil analisis korelasi menunjukkan bahwa hubungan antar indikator pembangunan dalam dataset cenderung lemah dan tidak signifikan secara statistik. Dengan demikian, pembangunan wilayah merupakan fenomena yang kompleks dan dipengaruhi oleh berbagai faktor yang saling berkaitan.

4.2 Insight

1. Ketimpangan ekonomi antar wilayah masih terlihat dari adanya outlier pada variabel PDRB per kapita.
2. Variabel pembangunan manusia seperti IPM, harapan hidup, dan rata-rata lama sekolah memiliki distribusi yang relatif stabil.
3. Hubungan antar indikator pembangunan pada dataset tidak menunjukkan pola linear yang kuat.
4. Analisis pembangunan wilayah memerlukan pendekatan multivariat karena satu indikator tidak cukup menjelaskan kondisi pembangunan secara keseluruhan.

4.3 Saran

1. Menambahkan variabel lain seperti investasi daerah, tingkat urbanisasi, dan pengeluaran pemerintah agar analisis lebih komprehensif.
2. Melakukan analisis regresi atau machine learning untuk mengidentifikasi faktor yang paling berpengaruh terhadap pembangunan wilayah.
3. Melakukan visualisasi yang lebih mendalam menggunakan histogram, scatter plot, dan heatmap korelasi.
4. Memperbarui dataset secara berkala agar hasil analisis dapat mencerminkan kondisi pembangunan yang lebih aktual.

LAMPIRAN

5.1 Script R

```
# =====  
# 1.3.1 Memahami Dataset  
# =====  
data_pembangunan <-  
  ↪ read.csv("../dataset/pembangunan_wilayah_missing_outlier.csv")  
( "--- STRUKTUR DATA ---")  
str(data_pembangunan)  
  
( "--- 6 BARIS PERTAMA DATASET ---")  
head(data_pembangunan)  
  
( "--- SUMMARY ---")  
summary(data_pembangunan)  
  
dimensi <- dim(data_pembangunan)  
cat("Jumlah Observasi (Baris) :", dimensi[1])  
cat("Jumlah Variabel (Kolom) :", dimensi[2])  
  
# =====  
# 1.3.2 Statistika Deskriptif  
# =====  
( "--- Mengambil variabel numerik ---")  
data_numerik <- data_pembangunan[sapply(data_pembangunan, is.numeric)]  
  
( "--- Ringkasan statistik deskriptif ---")
```

```

summary(data_numerik)

("--- Mean ---")
sapply(data_numerik, mean, na.rm = TRUE)

("--- Median ---")
sapply(data_numerik, median, na.rm = TRUE)

("--- Nilai minimum ---")
sapply(data_numerik, min, na.rm = TRUE)

("--- Nilai maksimum ---")
sapply(data_numerik, max, na.rm = TRUE)

("--- Standar deviasi ---")
sapply(data_numerik, sd, na.rm = TRUE)

("--- Varians ---")
sapply(data_numerik, var, na.rm = TRUE)

("--- Kuartil ---")
sapply(data_numerik, quantile, na.rm = TRUE)

# =====
# 1.3.3 Analisis Missing Value
# =====

("--- Memeriksa jumlah missing value di tiap variabel ---")
missing_value <- colSums(is.na(data_pembangunan))

```

```

("--- Merepresentasikan jumlah missing value tiap variabel ke dalam
  ↳ persentase ---")
percentage_missing_value <- missing_value / nrow(data_pembangunan) * 100

("--- Menghitung rata-rata persentase missing value dataframe (secara
  ↳ keseluruhan) ---")
percentage_missing_value_df <- mean(is.na(data_pembangunan)) * 100

("--- Melihat hasil perhitungan persentase ---")
print(percentage_missing_value_df)

("--- Karena persentase 0.4% < 30%, maka metode yang diambil adalah metode
  ↳ penghapusan ---")
data_pembangunan <- na.omit(data_pembangunan)

("--- Memeriksa kembali apakah jumlah baris dataset sudah diperbarui setelah
  ↳ penghapusan ---")
print(nrow(data_pembangunan))

# =====
# 1.3.4 Analisis Outlier
# =====

("--- Mengambil kolom variabel yang bertipe data numerik ---")
numeric_columns_name <- names(data_pembangunan)[apply(data_pembangunan,
  ↳ is.numeric)]

("--- Menghitung IQR tiap kolom numerik ---")
for(column_name in numeric_columns_name) {
  Q1 <- quantile(data_pembangunan[[column_name]], 0.25, na.rm = TRUE)

```

```

Q3 <- quantile(data_pembangunan[[column_name]], 0.75, na.rm = TRUE)

IQR <- Q3 - Q1

lower_bound <- Q1 - 1.5 * IQR
upper_bound <- Q3 + 1.5 * IQR

total_outlier <- sum(data_pembangunan[[column_name]] < lower_bound |
  ⇨ data_pembangunan[[column_name]] > upper_bound, na.rm = TRUE)

cat(column_name, ":", total_outlier, "outlier\n")
}

("--- Membuat beberapa boxplot untuk visualisasi outlier ---")
par(mfrow = c(2, 3))

for(col in numeric_columns_name) {
  boxplot(data_pembangunan[[col]], main = col)
}

# Bagian : 1.3.5 Visualisasi Data
#           1.3.6 Analisis Probabilitas dan Distribusi Data

library(ggplot2)
data <- read.csv(
  "data/pembangunan_wilayah_missing_outlier.csv"
)

```

```

#bersihin Missing Value

data_clean <- na.omit(data)

cat("Jumlah data sebelum pembersihan :", nrow(data), "\n")
cat("Jumlah data setelah pembersihan :", nrow(data_clean), "\n")

# =====
# 1.3.5 VISUALISASI DATA
# =====

# Grafik 1 : Histogram IPM

ggplot(data_clean, aes(x = ipm)) +
  geom_histogram(binwidth = 3) +
  labs(
    title = "Distribusi Nilai IPM",
    x = "IPM",
    y = "Frekuensi"
  )

# Grafik 2 : Histogram Kemiskinan

ggplot(data_clean, aes(x = kemiskinan)) +
  geom_histogram(binwidth = 2) +
  labs(
    title = "Distribusi Tingkat Kemiskinan",
    x = "Kemiskinan (%)",
    y = "Frekuensi"
  )

```



```

)

# Grafik 3 : Boxplot PDRB Per Kapita

ggplot(data_clean, aes(y = pdrb_perkapita)) +
  geom_boxplot() +
  labs(
    title = "Boxplot PDRB Per Kapita",
    y = "PDRB Per Kapita"
  )

# Grafik 4 : Scatter Plot Kemiskinan vs IPM

ggplot(data_clean,
  aes(
    x = kemiskinan,
    y = ipm
  )) +
  geom_point() +
  labs(
    title = "Hubungan Kemiskinan dan IPM",
    x = "Kemiskinan (%)",
    y = "IPM"
  )

# Grafik 5 : Scatter Plot Akses Internet
#               vs Rata Lama Sekolah

ggplot(data_clean,

```

```

    aes(
      x = akses_internet,
      y = rata_lama_sekolah
    ) +
  geom_point() +
  labs(
    title = "Hubungan Akses Internet dan Rata Lama Sekolah",
    x = "Akses Internet (%)",
    y = "Rata Lama Sekolah (Tahun)"
  )

# =====
# 1.3.6 ANALISIS DISTRIBUSI DATA
# =====

# Uji Normalitas Shapiro-Wilk

shapiro_ipm <- shapiro.test(data_clean$ipm)
shapiro_kemiskinan <- shapiro.test(data_clean$kemiskinan)
shapiro_internet <- shapiro.test(data_clean$akses_internet)

cat("\n")
cat("=====\n")
cat("HASIL UJI NORMALITAS\n")
cat("=====\n")

print(shapiro_ipm)
print(shapiro_kemiskinan)
print(shapiro_internet)

```

```

# QQ Plot IPM

qqnorm(data_clean$ipm,
      main = "QQ Plot IPM")
qqline(data_clean$ipm)

# QQ Plot Kemiskinan

qqnorm(data_clean$kemiskinan,
      main = "QQ Plot Kemiskinan")
qqline(data_clean$kemiskinan)

# =====
# ANALISIS PROBABILITAS
# =====

# Probabilitas Kemiskinan
# di atas rata-rata

mean_kemiskinan <- mean(data_clean$kemiskinan)

prob_kemiskinan_atas_rata <- mean(
  data_clean$kemiskinan > mean_kemiskinan
)

cat("\n")
cat("=====\n")
cat("PROBABILITAS KEMISKINAN\n")

```

```

cat("=====\n")

cat(
  "Probabilitas wilayah memiliki kemiskinan di atas rata-rata = ",
  round(prob_kemiskinan_atas_rata,4),
  "\n"
)

# Probabilitas IPM > 75

prob_ipm_tinggi <- mean(
  data_clean$ipm > 75
)

cat(
  "Probabilitas wilayah memiliki IPM > 75 = ",
  round(prob_ipm_tinggi,4),
  "\n"
)

# Probabilitas Normal pakai pnorm()
# P(IPM < 75)

prob_normal_ipm <- pnorm(
  75,
  mean(data_clean$ipm),
  sd(data_clean$ipm)
)

```

```

cat(
  "Probabilitas IPM kurang dari 75 (Distribusi Normal) = ",
  round(prob_normal_ipm,4),
  "\n"
)

# Nilai IPM pada persentil ke-95
# pakai qnorm()

ipm_p95 <- qnorm(
  0.95,
  mean(data_clean$ipm),
  sd(data_clean$ipm)
)

cat(
  "Nilai IPM pada persentil ke-95 = ",
  round(ipm_p95,2),
  "\n"
)

# =====
# TABEL RINGKAS HASIL UJI NORMALITAS
# =====

hasil_normalitas <- data.frame(
  Variabel = c(
    "IPM",
    "Kemiskinan",

```

```

    "Akses Internet"
  ),
  P_Value = c(
    shapiro_ipm$p.value,
    shapiro_kemiskinan$p.value,
    shapiro_internet$p.value
  )
)

hasil_normalitas$Kesimpulan <-
  ifelse(
    hasil_normalitas$P_Value > 0.05,
    "Berdistribusi Normal",
    "Tidak Berdistribusi Normal"
  )

cat("\n")
cat("=====\n")
cat("TABEL HASIL UJI NORMALITAS\n")
cat("=====\n")

print(hasil_normalitas)

# =====
# 1.3.7 Analisis Korelasi
# =====

data_bersih <- data_pembangunan[complete.cases(data_pembangunan), ]
kolom_numerik_korelasi <- c("pdrb_perkapita", "kemiskinan", "pengangguran",
  ↪ "ipm",

```

```

        "harapan_hidup", "rata_lama_sekolah",
        ↪ "akses_internet",
        "jalan_baik", "air_bersih")

matriks_numerik <- data_bersih[, kolom_numerik_korelasi]

cat("--- Menghitung korelasi antar variabel ---")
matriks_korelasi <- cor(matriks_numerik, method = "pearson")
print(round(matriks_korelasi, 3))

cat("--- UJI KORELASI: IPM vs KEMISKINAN ---")
uji_ipm_kemiskinan <- cor.test(data_bersih$ipm, data_bersih$kemiskinan)
print(uji_ipm_kemiskinan)

cat("--- UJI KORELASI: AKSES INTERNET vs RATA-LAMA SEKOLAH ---")
uji_internet_sekolah <- cor.test(data_bersih$akses_internet,
    ↪ data_bersih$rata_lama_sekolah)
print(uji_internet_sekolah)

cat("--- UJI KORELASI: PDRB PERKAPITA vs IPM (KESEJAHTERAAN) ---")
uji_pdrb_ipm <- cor.test(data_bersih$pdrb_perkapita, data_bersih$ipm)
print(uji_pdrb_ipm)

```

5.2 Output Tambahan

##	wilayah	provinsi	tahun	pdrb_perkapita
##	"character"	"character"	"integer"	"numeric"
##	kemiskinan	pengangguran	ipm	harapan_hidup
##	"numeric"	"numeric"	"numeric"	"numeric"

```

## rata_lama_sekolah akses_internet jalan_baik air_bersih
## "numeric" "numeric" "numeric" "numeric"
## catatan_data
## "character"

## wilayah provinsi tahun pdrb_perkapita kemiskinan
## 1 Kabupaten/Kota_1 Jawa Barat 2022 38403994 19.69
## 2 Kabupaten/Kota_2 Jawa Timur 2022 165582092 9.68
## 3 Kabupaten/Kota_3 Kalimantan Timur 2020 26780948 4.13
## 4 Kabupaten/Kota_4 DKI Jakarta 2022 155034790 20.43
## 5 Kabupaten/Kota_5 Sulawesi Selatan 2023 198834591 14.39
## 6 Kabupaten/Kota_6 Jawa Timur 2020 145702606 17.14
## pengangguran ipm harapan_hidup rata_lama_sekolah akses_internet jalan_baik
## 1 4.73 80.16 75.75 8.41 63.86 53.86
## 2 4.43 55.05 67.85 5.79 66.61 34.89
## 3 2.99 78.70 60.38 13.20 64.73 48.57
## 4 3.90 73.27 69.49 12.28 44.59 57.88
## 5 12.15 72.90 75.00 9.69 52.72 65.70
## 6 3.38 65.11 67.04 5.66 55.63 70.12
## air_bersih catatan_data
## 1 43.11 Normal
## 2 58.93 Normal
## 3 90.27 Normal
## 4 86.16 Normal
## 5 90.84 Normal
## 6 60.17 Normal

## wilayah provinsi tahun pdrb_perkapita
## Length:2500 Length:2500 Min. :2020 Min. :1.503e+07
## Class :character Class :character 1st Qu.:2021 1st Qu.:6.962e+07
## Mode :character Mode :character Median :2022 Median :1.373e+08

```



```

##                               Mean    :2022    Mean    :1.357e+08
##                               3rd Qu.:2023    3rd Qu.:1.939e+08
##                               Max.     :2024    Max.     :1.775e+09
##                               NA's     :25
##      kemiskinan      pengangguran      ipm      harapan_hidup
## Min.      : 2.01    Min.      : 1.010    Min.      :55.01    Min.      :60.01
## 1st Qu.: 7.86    1st Qu.: 4.350    1st Qu.:62.52    1st Qu.:64.66
## Median :13.72    Median : 8.230    Median :69.89    Median :69.30
## Mean      :13.72    Mean      : 8.046    Mean      :69.90    Mean      :69.13
## 3rd Qu.:19.39    3rd Qu.:11.520    3rd Qu.:77.16    3rd Qu.:73.58
## Max.      :67.53    Max.      :47.040    Max.      :84.99    Max.      :77.99
## NA's      :24      NA's      :25      NA's      :25
## rata_lama_sekolah akses_internet      jalan_baik      air_bersih
## Min.      : 5.020    Min.      : 0.01    Min.      :30.01    Min.      :40.03
## 1st Qu.: 7.327    1st Qu.:38.91    1st Qu.:47.40    1st Qu.:54.32
## Median : 9.520    Median :58.09    Median :65.02    Median :69.68
## Mean      : 9.581    Mean      :58.79    Mean      :65.26    Mean      :69.76
## 3rd Qu.:11.912    3rd Qu.:78.67    3rd Qu.:83.24    3rd Qu.:85.18
## Max.      :14.000    Max.      :97.99    Max.      :99.95    Max.      :99.99
##                               NA's      :25      NA's      :25
## catatan_data
## Length:2500
## Class :character
## Mode  :character
##
##
##
##

## Jumlah Observasi (Baris) : 2500

```

Jumlah Variabel (Kolom) : 13

##	tahun	pdrb_perkapita	kemiskinan	pengangguran
##	Min. :2020	Min. :1.503e+07	Min. : 2.01	Min. : 1.010
##	1st Qu.:2021	1st Qu.:6.962e+07	1st Qu.: 7.86	1st Qu.: 4.350
##	Median :2022	Median :1.373e+08	Median :13.72	Median : 8.230
##	Mean :2022	Mean :1.357e+08	Mean :13.72	Mean : 8.046
##	3rd Qu.:2023	3rd Qu.:1.939e+08	3rd Qu.:19.39	3rd Qu.:11.520
##	Max. :2024	Max. :1.775e+09	Max. :67.53	Max. :47.040
##		NA's :25	NA's :24	NA's :25

##	ipm	harapan_hidup	rata_lama_sekolah	akses_internet
##	Min. :55.01	Min. :60.01	Min. : 5.020	Min. : 0.01
##	1st Qu.:62.52	1st Qu.:64.66	1st Qu.: 7.327	1st Qu.:38.91
##	Median :69.89	Median :69.30	Median : 9.520	Median :58.09
##	Mean :69.90	Mean :69.13	Mean : 9.581	Mean :58.79
##	3rd Qu.:77.16	3rd Qu.:73.58	3rd Qu.:11.912	3rd Qu.:78.67
##	Max. :84.99	Max. :77.99	Max. :14.000	Max. :97.99
##	NA's :25			NA's :25

##	jalan_baik	air_bersih
##	Min. :30.01	Min. :40.03
##	1st Qu.:47.40	1st Qu.:54.32
##	Median :65.02	Median :69.68
##	Mean :65.26	Mean :69.76
##	3rd Qu.:83.24	3rd Qu.:85.18
##	Max. :99.95	Max. :99.99
##	NA's :25	

##	tahun	pdrb_perkapita	kemiskinan	pengangguran
##	2.021999e+03	1.356505e+08	1.372146e+01	8.045733e+00
##	ipm	harapan_hidup	rata_lama_sekolah	akses_internet
##	6.989999e+01	6.913015e+01	9.580684e+00	5.878903e+01

##	jalan_baik	air_bersih		
##	6.525808e+01	6.976153e+01		
##	tahun	pdrb_perkapita	kemiskinan	pengangguran
##	2.022000e+03	1.373106e+08	1.372000e+01	8.230000e+00
##	ipm	harapan_hidup	rata_lama_sekolah	akses_internet
##	6.989000e+01	6.929500e+01	9.520000e+00	5.809000e+01
##	jalan_baik	air_bersih		
##	6.502000e+01	6.968000e+01		
##	tahun	pdrb_perkapita	kemiskinan	pengangguran
##	2020.00	15031581.00	2.01	1.01
##	ipm	harapan_hidup	rata_lama_sekolah	akses_internet
##	55.01	60.01	5.02	0.01
##	jalan_baik	air_bersih		
##	30.01	40.03		
##	tahun	pdrb_perkapita	kemiskinan	pengangguran
##	2.024000e+03	1.774545e+09	6.753000e+01	4.704000e+01
##	ipm	harapan_hidup	rata_lama_sekolah	akses_internet
##	8.499000e+01	7.799000e+01	1.400000e+01	9.799000e+01
##	jalan_baik	air_bersih		
##	9.995000e+01	9.999000e+01		
##	tahun	pdrb_perkapita	kemiskinan	pengangguran
##	1.431789e+00	8.934127e+07	6.894704e+00	4.258576e+00
##	ipm	harapan_hidup	rata_lama_sekolah	akses_internet
##	8.535062e+00	5.171779e+00	2.627008e+00	2.282030e+01
##	jalan_baik	air_bersih		
##	2.036569e+01	1.749921e+01		

```
##          tahun      pdrb_perkapita      kemiskinan      pengangguran
##      2.050019e+00      7.981863e+15      4.753694e+01      1.813547e+01
##          ipm      harapan_hidup rata_lama_sekolah      akses_internet
##      7.284728e+01      2.674730e+01      6.901173e+00      5.207660e+02
##      jalan_baik      air_bersih
##      4.147613e+02      3.062222e+02
```

```
##      tahun pdrb_perkapita kemiskinan pengangguran      ipm harapan_hidup
## 0%      2020      15031581      2.0100      1.01 55.01      60.0100
## 25%      2021      69622210      7.8600      4.35 62.52      64.6575
## 50%      2022      137310624      13.7200      8.23 69.89      69.2950
## 75%      2023      193899157      19.3925      11.52 77.16      73.5850
## 100%      2024      1774545027      67.5300      47.04 84.99      77.9900
```

```
##      rata_lama_sekolah akses_internet jalan_baik air_bersih
## 0%      5.0200      0.010      30.010      40.0300
## 25%      7.3275      38.915      47.395      54.3175
## 50%      9.5200      58.090      65.020      69.6800
## 75%      11.9125      78.670      83.240      85.1825
## 100%      14.0000      97.990      99.950      99.9900
```

```
## [1] 0.4584615
```

```
## [1] 2357
```

```
## [1] "--- Menghitung IQR tiap kolom numerik ---"
```

```
## tahun : 0 outlier
```


```
## pdrb_perkapita : 5 outlier
```

```
## kemiskinan : 5 outlier
```

```
## pengangguran : 5 outlier
```

```
## ipm : 0 outlier
```

```
## harapan_hidup : 0 outlier
## rata_lama_sekolah : 0 outlier
## akses_internet : 0 outlier
## jalan_baik : 0 outlier
## air_bersih : 0 outlier
```



```
## Jumlah data sebelum pembersihan : 2500
```

```
## Jumlah data setelah pembersihan : 2357
```


```
## =====
```

```
## HASIL UJI NORMALITAS
```

```
## =====
```

```
##  
## Shapiro-Wilk normality test  
##  
## data:  data_clean$ipm  
## W = 0.95873, p-value < 2.2e-16  
  
##  
## Shapiro-Wilk normality test  
##  
## data:  data_clean$kemiskinan  
## W = 0.9425, p-value < 2.2e-16  
  
##  
## Shapiro-Wilk normality test  
##  
## data:  data_clean$akses_internet  
## W = 0.9566, p-value < 2.2e-16
```

Hubungan Akses Internet dan Rata Lama Sekolah



```
## Probabilitas wilayah memiliki kemiskinan di atas rata-rata = 0.4968
```

```
## Probabilitas wilayah memiliki IPM > 75 = 0.3275
```

```
## Probabilitas IPM kurang dari 75 (Distribusi Normal) = 0.7204
```

```
## Nilai IPM pada persentil ke-95 = 84.06
```

##	Variabel	P_Value	Kesimpulan
## 1	IPM	2.379285e-25	Tidak Berdistribusi Normal
## 2	Kemiskinan	2.377348e-29	Tidak Berdistribusi Normal
## 3	Akses Internet	6.137887e-26	Tidak Berdistribusi Normal

##	pdrb_perkapita	kemiskinan	pengangguran	ipm	harapan_hidup
## pdrb_perkapita	1.000	-0.002	-0.028	0.009	0.011

```

## kemiskinan          -0.002      1.000      -0.011  0.019      -0.009
## pengangguran        -0.028     -0.011       1.000  0.001       0.004
## ipm                  0.009      0.019       0.001  1.000       0.020
## harapan_hidup        0.011     -0.009       0.004  0.020       1.000
## rata_lama_sekolah    -0.002      0.010       0.008  0.018      -0.013
## akses_internet       -0.008     -0.032       0.027 -0.001       0.004
## jalan_baik           0.040      0.020      -0.005  0.025       0.000
## air_bersih           -0.005      0.009       0.008  0.025      -0.025

##          rata_lama_sekolah akses_internet jalan_baik air_bersih
## pdrb_perkapita        -0.002      -0.008      0.040     -0.005
## kemiskinan            0.010      -0.032      0.020      0.009
## pengangguran          0.008       0.027     -0.005      0.008
## ipm                   0.018      -0.001      0.025      0.025
## harapan_hidup         -0.013       0.004      0.000     -0.025
## rata_lama_sekolah      1.000      -0.014      0.052      0.019
## akses_internet        -0.014       1.000     -0.004     -0.007
## jalan_baik             0.052      -0.004      1.000      0.022
## air_bersih             0.019      -0.007      0.022      1.000

##
## Pearson's product-moment correlation
##
## data:  data_bersih$ipm and data_bersih$kemiskinan
## t = 0.91114, df = 2355, p-value = 0.3623
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.02161901  0.05910187
## sample estimates:
##          cor
## 0.01877202

```



```

##
## Pearson's product-moment correlation
##
## data:  data_bersih$akses_internet and data_bersih$rata_lama_sekolah
## t = -0.68127, df = 2355, p-value = 0.4958
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.05438095  0.02635246
## sample estimates:
##           cor
## -0.01403712

##
## Pearson's product-moment correlation
##
## data:  data_bersih$pdrb_perkapita and data_bersih$ipm
## t = 0.43587, df = 2355, p-value = 0.663
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.03140471  0.04933808
## sample estimates:
##           cor
## 0.008981327

```