

ANALISIS DATA PEMBANGUNAN WILAYAH MENGUNAKAN R

Disusun Oleh:

Muhamad Akbar Zainuri	J0403251008
Zalfa Nazla Azkiya	J0403251037
Diaz Ramaananta Harahap	J0403251048
Dede Risma Komalasari	J0403251049
Nashira Salima Firmansyah	J0403251056
Fahrizal Azis	J0403251151



**MATA KULIAH PROBABILITAS & STATISTIKA
PROGRAM STUDI TEKNOLOGI REKAYASA PERANGKAT
LUNAK
SEKOLAH VOKASI
INSTITUT PERTANIAN BOGOR
BOGOR
2026**

DAFTAR ISI

COVER	i
DAFTAR ISI	ii
DAFTAR GAMBAR	iii
DAFTAR TABEL	iv
BAB I	1
1.1 Latar Belakang	1
1.2 Tujuan	1
BAB II	2
2.1 Dataset	2
2.2 Tools Yang Digunakan	2
2.3 Metode Analisis	3
BAB III	5
3.1 Statistika Deskriptif	5
3.2 Missing Value	6
3.3 Outlier	7
3.4 Visualisasi	9
3.5 Distribusi Data	9
3.6 Korelasi	9
3.7 Interpretasi	10
BAB IV	11
4.1 Kesimpulan Utama	11
4.2 Insight	11
4.3 Saran	12
LAMPIRAN	13
5.1 Script R	13
5.2 Output Tambahan	27

DAFTAR GAMBAR

Gambar 3.1 Boxplot Outlier	8
Gambar 3.2 Histogram Nilai IPM	10
Gambar 3.3 Histogram Tingkat Kemiskinan	10
Gambar 3.4 Boxplot PDRB Per Kapita	11
Gambar 3.5 Scatter Plot Kemiskinan dan IPM	12
Gambar 3.6 Scatter Plot Akses Internet dan Rata-rata Lama Sekolah	13
Gambar 3.7 QQ Plot Variabel IPM	15
Gambar 3.8 QQ Plot Variabel Kemiskinan	15

DAFTAR TABEL

Tabel 3.1 Hasil Statistika Deskriptif	5
Tabel 3.2 Hasil Analisis <i>Missing Value</i>	7
Tabel 3.3 Hasil Analisis <i>Outlier</i>	8
Tabel 3.4 Nilai-Nilai Outlier yang Terdeteksi	8
Tabel 3.5 Dampak <i>Outlier</i> terhadap Nilai Rata-Rata	9
Tabel 3.6 Hasil Analisis Korelasi	17
Tabel 3.7 Hasil Uji Normalitas Shapiro-Wilk	14

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pembangunan wilayah adalah sebuah proses yang bertujuan untuk meningkatkan kesejahteraan masyarakat. Untuk mengetahui bagaimana suatu pembangunan wilayah di suatu daerah berhasil diperlukan indikator yang dapat menggambarkan keadaan masyarakat di wilayah tersebut dengan jelas, seperti angka kemiskinan, pengangguran, Produk Domestik Regional Bruto (PDRB), serta indeks pembangunan Manusia (IPM).

Oleh karena itu, diperlukan analisis data untuk mengolah informasi yang ada agar dapat memberikan gambaran tentang kondisi pembangunan di suatu wilayah. Berdasarkan kebutuhan tersebut, proyek ini bertujuan untuk menganalisis data pembangunan wilayah di seluruh Indonesia dengan mengimplementasikan bahasa pemrograman R. Melalui proyek akhir ini, mahasiswa diharapkan dapat meningkatkan keterampilan mereka dalam mengolah, menganalisis, dan menginterpretasikan data terkait pembangunan daerah dengan memanfaatkan bahasa pemrograman R.

1.2 Tujuan

Proyek ini bertujuan untuk menganalisis data mengenai pembangunan wilayah di Indonesia dengan memanfaatkan bahasa pemrograman R. Analisis dilakukan untuk mengenali ciri-ciri data, memahami hubungan di antara indikator pembangunan, serta mengungkap faktor-faktor yang memengaruhi tingkat perkembangan suatu daerah. Di samping itu, proyek ini bertujuan untuk mengaplikasikan konsep statistika dan analisis data dalam menyelesaikan masalah yang ada serta menyajikan hasil analisis dengan cara yang terstruktur dan informatif.

BAB II

METODOLOGI

2.1 Dataset

Dataset adalah kumpulan data terstruktur yang digunakan untuk berbagai keperluan, seperti analisis, penelitian, atau pengolahan informasi lainnya (James *et al.* 2021). Di dalam sebuah dataset, terdapat sejumlah variabel yang disusun dalam bentuk tabel. Setiap kolom mewakili atribut tertentu, sementara setiap baris menggambarkan entitas atau observasi yang berbeda. Dataset menjadi komponen penting dalam pengolahan data, membantu menghasilkan informasi yang lebih bermakna dan bermanfaat.

Data yang digunakan dalam analisis ini adalah dataset skor pembangunan wilayah tingkat Kabupaten/Kota di Indonesia. Secara keseluruhan, dataset ini mencakup observasi 2.500 baris kabupaten/kota dengan 13 kolom variabel, yang berada dalam rentang waktu lima tahun, yaitu dari tahun 2020 hingga 2024. Berikut adalah rincian variabel-variabel yang telah dikelompokkan menjadi beberapa kategori:

1. Variabel Identitas Data : wilayah, provinsi, dan tahun.
2. Variabel Ekonomi : pdrb_perkapita, kemiskinan, dan pengangguran.
3. Variabel Pembangunan Manusia : ipm, harapan_hidup, rata_lama_sekolah.
4. Variabel Infrastruktur : akses_internet, jalan_baik, air_bersih.
5. Variabel Metadata : catatan_data.

Dataset pembangunan wilayah tersebut berbentuk dokumen .csv. Dokumen ini bisa diunduh melalui <https://pembangunanwilayahmissingoutlier.tiiny.site> untuk melihat dataset secara keseluruhan.

2.2 Tools Yang Digunakan

Dalam melakukan analisis data ini, digunakan perangkat lunak Rstudio dan library ggplot2 untuk menghasilkan informasi yang terstruktur dan akurat tentang pembangunan

wilayah di Indonesia. Berikut adalah rincian tools yang digunakan:

1. **Dataset format .csv:** Digunakan sebagai format penyimpanan data mentah yang menjadi objek utama analisis.
2. **Bahasa Pemrograman R:** R digunakan sebagai bahasa pemrograman utama untuk komputasi statistik dan analisis data (James *et al.* 2021). Bahasa ini dipilih karena memiliki kemampuan yang kuat dalam melakukan manipulasi data, serta menyediakan berbagai paket statistik yang mumpuni untuk melakukan analisis deskriptif maupun inferensial pada dataset.
3. **RStudio:** RStudio digunakan sebagai *Integrated Development Environment* (IDE) atau lingkungan pengembangan terintegrasi untuk menulis dan mengeksekusi kode R (Posit Software 2024). RStudio mempermudah manajemen proyek, pemantauan variabel, penanganan error melalui antarmuka yang interaktif, serta mendukung penyusunan laporan menggunakan R Markdown.
4. **Library ggplot2:** Library ggplot2 digunakan untuk memenuhi kebutuhan visualisasi data dan pembuatan grafik statistik (Wickham 2016). Library ini memungkinkan pembuatan grafik secara modular. Di dalam proyek ini, ggplot2 digunakan untuk menyajikan tren indikator pembangunan, mengidentifikasi sebaran data, serta memberikan visualisasi perbandingan kondisi antarwilayah secara informatif.
5. **Library xelatex:** Xelatex digunakan sebagai library untuk mengeksport laporan akhir proyek dari dokumen RMarkdown menjadi dokumen berformat .pdf.

2.3 Metode Analisis

Analisis data dilakukan menggunakan bahasa pemrograman R untuk memperoleh gambaran mengenai kondisi pembangunan wilayah di Indonesia. Tahapan analisis yang dilakukan adalah sebagai berikut:

1. **Pengumpulan Data:** Data yang digunakan merupakan data indikator pembangunan wilayah yang mencakup beberapa variabel pdrb_perkapita, kemiskinan, pengangguran, IPM, akses_internet, dll).

2. **Analisis Statistik Deskriptif:** Analisis statistik deskriptif dilakukan untuk menggambarkan karakteristik data melalui nilai minimum, nilai maksimum, rata-rata, median, standar deviasi, dan lain-lain.
3. **Analisis Missing Value:** Missing value dianalisis dengan menghitung jumlah dan persentase data yang hilang pada setiap variabel. Hasil analisis digunakan untuk menentukan metode penanganan yang sesuai.
4. **Analisis Outlier:** Deteksi outlier dilakukan menggunakan metode Interquartile Range (IQR). Suatu data dikatakan sebagai outlier apabila berada di luar batas.
5. **Visualisasi Data:** Visualisasi dilakukan untuk mempermudah interpretasi data menggunakan histogram, boxplot, scatter plot, dan heatmap korelasi.
6. **Analisis Korelasi:** Analisis korelasi digunakan untuk mengetahui hubungan antar indikator pembangunan wilayah. Kolerasi dihitung menggunakan koefisien korelasi pearson dengan rentang nilai $-1 \leq r \leq 1$. Nilai korelasi yang mendekati 1 menunjukkan hubungan positif yang kuat, sedangkan nilai yang mendekati -1 menunjukkan hubungan negatif yang kuat.

BAB III

HASIL DAN PEMBAHASAN

3.1 Statistika Deskriptif

Statistika deskriptif merupakan metode statistik yang digunakan untuk meringkas dan menggambarkan karakteristik utama dari suatu kumpulan data secara numerik (Walpole *et al.* 2018). Analisis ini bertujuan untuk memberikan gambaran awal mengenai kondisi data pembangunan wilayah melalui ukuran pemusatan dan penyebaran data (Walpole *et al.* 2018). khususnya terkait ukuran pemusatan data seperti mean dan median serta ukuran penyebaran data seperti standar deviasi, varians, dan rentang nilai.

Pada penelitian ini, analisis statistika deskriptif dilakukan terhadap seluruh variabel numerik pada dataset pembangunan wilayah menggunakan beberapa fungsi dalam bahasa pemrograman R seperti *summary()*, *mean()*, *median()*, *sd()*, *var()*, dan *quantile()*.

Tabel 3.1 Hasil Statistika Deskriptif

Variabel	Mean	SD	Keterangan
pdrb_perkapita	Tinggi	Paling besar	Penyebaran sangat tinggi
kemiskinan	13,72	Cukup besar	Terdapat variasi data
pengangguran	8	Besar	Indikasi data ekstrem
ipm	69–70	Relatif kecil	Distribusi stabil
harapan_hidup	69 tahun	Relatif kecil	Distribusi stabil
rata_lama_sekolah	9,5 tahun	Relatif kecil	Distribusi stabil

Berdasarkan hasil analisis, variabel *pdrb_perkapita* memiliki nilai rata-rata tertinggi dibandingkan variabel lainnya. Selain itu, variabel tersebut juga mempunyai standar deviasi terbesar yang menunjukkan bahwa terdapat perbedaan tingkat pendapatan yang cukup besar antar wilayah di Indonesia.

Variabel *kemiskinan* dan *pengangguran* juga menunjukkan penyebaran data yang cukup besar. Hal ini terlihat dari rentang nilai minimum dan maksimum yang jauh berbeda.

Pada variabel pengangguran, nilai maksimum bahkan jauh di atas rata-ratanya sehingga mengindikasikan adanya beberapa data ekstrem.

Sementara itu, variabel seperti *ipm*, *harapan_hidup*, dan *rata_lama_sekolah* memiliki nilai mean dan median yang relatif berdekatan. Kondisi tersebut menunjukkan bahwa distribusi data pada variabel pembangunan manusia cenderung lebih stabil dan tidak terlalu menyebar.

Perbedaan mean dan median yang cukup jauh pada beberapa variabel ekonomi memberikan indikasi awal bahwa data kemungkinan tidak berdistribusi normal serta terdapat outlier pada beberapa wilayah. Oleh karena itu, analisis lanjutan mengenai missing value dan outlier perlu dilakukan pada tahap berikutnya.

3.2 Missing Value

Menurut Rianto & Santosa (2024), *Missing value*, atau data yang hilang, terjadi ketika salah satu kolom atau atribut dalam dataset tidak memiliki nilai. Hal ini bisa disebabkan oleh kesalahan pencatatan, keterbatasan teknis selama proses pengumpulan data, atau kondisi tertentu di mana data memang tidak tersedia.

Pada penelitian ini, penanganan dilakukan terhadap baris data yang memiliki *missing value* dalam dataset pembangunan wilayah menggunakan bahasa pemrograman R, yang dimulai dengan mengukur terlebih dahulu seberapa besar pengaruhnya dalam data.

Tabel 3.2 Hasil Analisis *Missing Value*

Variabel	Missing Value	Persentase
pdrb_perkapita	25	1%
kemiskinan	24	0.96%
pengangguran	25	1%
IPM	25	1%
akses_internet	25	1%
jalan_baik	25	1%
Rata-Rata Persentase		0.45%

Berdasarkan hasil analisis, ditemukan *missing value* pada beberapa variabel seperti *pdrb_perkapita*, *kemiskinan*, *pengangguran*, *IPM*, *akses_internet*, dan *jalan_baik*. Keberadaan *missing value* ini dapat mempengaruhi hasil analisis statistik, salah satu contohnya adalah mengurangi jumlah observasi yang dapat di analisis.

Data yang memiliki nilai kosong tidak dapat digunakan secara langsung dalam berbagai metode statistik. Akibatnya, jumlah data yang tersedia untuk analisis menjadi berkurang sehingga informasi yang diperoleh menjadi kurang lengkap.

Untuk metode penanganan *missing value* itu sendiri, yang kami gunakan adalah penghapusan. Metode ini dipilih karena proporsi data yang hilang pada setiap variabel relatif kecil yaitu 1% dari total observasi, dimana tidak menyebabkan berkurangnya representativitas data secara signifikan, sehingga dampaknya terhadap analisis diperkirakan sangat kecil.

Alasan lainnya adalah, metode ini sederhana dan sangat efektif jika jumlah *missing value* kecil, misalnya 1-2% dari data. Namun, jika jumlah data yang hilang mencapai 30% atau lebih, metode ini beresiko mengurangi informasi penting dan tidak disarankan (Rianto & Santosa, 2024).

3.3 Outlier

Outlier merupakan data yang memiliki nilai jauh berbeda dibandingkan sebagian besar observasi lainnya. Pada penelitian ini, deteksi outlier dilakukan menggunakan metode


Interquartile Range (IQR) dengan batas bawah $Q1 - 1.5 \times IQR$ dan batas atas $Q3 + 1.5 \times IQR$ (Montgomery dan Runger 2018). *Outlier* adalah nilai yang berbeda secara signifikan dari sebagian besar data lainnya, sering kali muncul karena kesalahan pengukuran, variasi alami, atau anomali yang tidak terduga. *Outlier* dapat berdampak negatif pada analisis, seperti menggeser rata-rata. Oleh karena itu, deteksi dan penanganan *outlier* menjadi langkah penting yang harus dilakukan.

Pada penelitian ini, dataset pembangunan wilayah memiliki outlier pada sejumlah variabel, yaitu *pdrb_perkapita*, *kemiskinan*, dan *pengangguran*. Berikut penjabaran seberapa banyak outlier yang dimiliki setiap variabel tersebut.

Tabel 3.3 Hasil Analisis *Outlier*

Variabel	Jumlah Outlier
pdrb_perkapita	5
kemiskinan	5
pengangguran	5

Gambar 3.1 Boxplot Outlier



Tabel 3.4 Nilai-Nilai *Outlier* yang Terdeteksi

pdrb_perkapita	kemiskinan	pengangguran
1.012.449.971	45,95	33,19
1.087.231.959	47,69	34,90
1.472.419.961	53,50	36,68
1.474.832.345	58,41	36,74
1.774.545.027	67,53	47,04

Dalam analisis ini, metode deteksi *outlier* yang kami gunakan adalah **IQR**. Metode ini mengidentifikasi *outlier* dengan menghitung rentang antara kuartil pertama (Q1) dan kuartil ketiga (Q3). Nilai yang berada diluar rentang $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ dianggap sebagai *outlier* (Rianto & Santosa, 2024).

Nilai *outlier* juga memiliki dampak besar terhadap analisis statistik, salah satu contohnya adalah, *outlier* dapat menarik ukuran pemusatan data ke arah nilai ekstrem. Berikut tabel dampak nilai *outlier* yang sudah di analisis.

Tabel 3.5 Dampak *Outlier* terhadap Nilai Rata-Rata

Variabel	Mean Sebelum Penghapusan	Mean Setelah Penghapusan	Selisih
pdrb_perkapita	135.650.462	133.163.326	2.487.136
kemiskinan	13.72	13.64	0.08
pengangguran	8.05	7.99	0.06

Variabel *pdrb_perkapita* mengalami perubahan rata-rata terbesar setelah *outlier* dihapus, yaitu sebesar 2.487.136. Ini menunjukkan bahwa keberadaan beberapa daerah dengan nilai *pdrb_perkapita* yang sangat tinggi memberikan pengaruh yang cukup besar terhadap nilai rata-rata keseluruhan. Sementara itu, variabel kemiskinan dan pengangguran hanya mengalami perubahan rata-rata yang relatif kecil, sehingga pengaruh *outlier* terhadap kedua variabel tersebut tidak sebesar pada variabel *pdrb_perkapita*.


3.4 Visualisasi

Visualisasi data merupakan salah satu teknik analisis yang digunakan untuk menyajikan informasi dalam bentuk grafik sehingga pola, tren, serta karakteristik data dapat dipahami dengan lebih mudah. Pada penelitian ini, visualisasi dilakukan menggunakan library *ggplot2* pada bahasa pemrograman R untuk membantu proses interpretasi data pembangunan wilayah di Indonesia.

Beberapa jenis visualisasi yang digunakan meliputi histogram, boxplot, dan scatter plot. Histogram digunakan untuk melihat distribusi data pada variabel *ipm* dan *kemiskinan*,


boxplot digunakan untuk mengidentifikasi keberadaan *outlier* pada variabel *pdrb_perkapita*, sedangkan scatter plot digunakan untuk mengamati hubungan antar variabel pembangunan wilayah.

Gambar 3.2 Histogram Nilai IPM




Berdasarkan histogram nilai IPM, sebagian besar data terkonsentrasi pada rentang nilai menengah hingga tinggi. Hal ini menunjukkan bahwa mayoritas kabupaten/kota di Indonesia memiliki tingkat pembangunan manusia yang relatif baik. Distribusi data juga terlihat cukup terpusat dengan penyebaran yang tidak terlalu ekstrem.

Gambar 3.3 Histogram Tingkat Kemiskinan



Histogram tingkat kemiskinan menunjukkan bahwa sebagian besar wilayah memiliki persentase kemiskinan pada kategori rendah hingga sedang. Namun demikian, terdapat beberapa wilayah dengan tingkat kemiskinan yang relatif tinggi sehingga menyebabkan distribusi data cenderung memanjang pada bagian kanan.


Gambar 3.4 Boxplot PDRB Per Kapita



Boxplot variabel *pdrb_perkapita* menunjukkan adanya beberapa nilai ekstrem yang berada di luar batas whisker. Hasil ini sejalan dengan analisis *outlier* sebelumnya yang menunjukkan bahwa terdapat sejumlah wilayah dengan nilai PDRB per kapita yang jauh lebih tinggi dibandingkan mayoritas wilayah lainnya.


Gambar 3.5 Scatter Plot Kemiskinan dan IPM

Hubungan Kemiskinan dan IPM



Scatter plot antara tingkat kemiskinan dan IPM menunjukkan adanya kecenderungan hubungan negatif. Secara umum, wilayah dengan tingkat kemiskinan yang lebih tinggi cenderung memiliki nilai IPM yang lebih rendah. Akan tetapi, pola hubungan yang terbentuk tidak terlalu kuat karena penyebaran titik data masih cukup luas.

Gambar 3.6 Scatter Plot Akses Internet dan Rata-rata Lama Sekolah



Hubungan antara akses internet dan rata-rata lama sekolah menunjukkan kecenderungan hubungan positif. Wilayah dengan akses internet yang lebih tinggi umumnya memiliki rata-rata lama sekolah yang lebih baik. Meskipun demikian, penyebaran titik yang cukup luas menunjukkan bahwa terdapat faktor lain yang turut memengaruhi tingkat pendidikan masyarakat.

Secara keseluruhan, visualisasi data memberikan gambaran yang lebih jelas mengenai karakteristik pembangunan wilayah di Indonesia. Hasil visualisasi juga mendukung analisis sebelumnya terkait keberadaan *outlier* serta adanya variasi kondisi pembangunan antar-wilayah.

3.5 Distribusi Data

Analisis distribusi data dilakukan untuk mengetahui karakteristik sebaran data serta menilai apakah data mengikuti distribusi normal atau tidak. Pada penelitian ini digunakan uji normalitas Shapiro-Wilk terhadap beberapa variabel, yaitu *ipm*, *kemiskinan*, dan *akses_internet*. Uji normalitas Shapiro-Wilk digunakan untuk mengetahui apakah suatu variabel mengikuti distribusi normal atau tidak. Suatu data dianggap berdistribusi normal apabila nilai p-value lebih besar dari 0,05 (Montgomery dan Runger 2018). Selain itu,


distribusi data juga diamati menggunakan QQ Plot untuk membandingkan distribusi data aktual dengan distribusi normal teoritis.

Tabel 3.7 Hasil Uji Normalitas Shapiro-Wilk


Variabel	P-Value	Kesimpulan
IPM	ISI_HASIL_R	ISI_HASIL_R
Kemiskinan	ISI_HASIL_R	ISI_HASIL_R
Akses Internet	ISI_HASIL_R	ISI_HASIL_R

Uji normalitas Shapiro-Wilk dilakukan dengan tingkat signifikansi sebesar 5% ($\alpha = 0,05$). Apabila nilai *p-value* lebih besar dari 0,05 maka data dianggap berdistribusi normal. Sebaliknya, apabila nilai *p-value* lebih kecil dari 0,05 maka data dinyatakan tidak berdistribusi normal.

Gambar 3.7 QQ Plot Variabel IPM



Gambar 3.8 QQ Plot Variabel Kemiskinan



Berdasarkan hasil visualisasi QQ Plot, sebagian besar titik data berada di sekitar garis diagonal. Hal ini menunjukkan bahwa distribusi data masih memiliki kemiripan dengan distribusi normal. Akan tetapi, pada bagian ekor distribusi terdapat beberapa titik yang menyimpang dari garis referensi sehingga menunjukkan adanya deviasi terhadap distribusi normal sempurna.

Penyimpangan tersebut kemungkinan dipengaruhi oleh variasi kondisi pembangunan antarwilayah serta keberadaan nilai ekstrem yang telah teridentifikasi pada analisis *outlier*. Faktor tersebut menyebabkan distribusi data menjadi tidak sepenuhnya simetris.

Selain analisis distribusi, dilakukan pula analisis probabilitas untuk memperoleh gambaran peluang terjadinya suatu kondisi pada data pembangunan wilayah. Analisis probabilitas dilakukan menggunakan peluang empiris berdasarkan data aktual serta fungsi distribusi normal pada variabel IPM.

Hasil perhitungan menunjukkan peluang suatu wilayah memiliki tingkat kemiskinan di atas rata-rata sebesar **ISI_HASIL_R**. Sementara itu, peluang suatu wilayah memiliki nilai IPM lebih dari 75 adalah sebesar **ISI_HASIL_R**. Berdasarkan pendekatan distribusi normal, peluang nilai IPM kurang dari 75 diperoleh sebesar **ISI_HASIL_R**.

Selain itu, hasil perhitungan persentil ke-95 menunjukkan bahwa nilai IPM sebesar **ISI_HASIL_R** dapat dijadikan batas atas yang hanya dicapai oleh sekitar 5% wilayah dengan tingkat pembangunan manusia tertinggi.

Secara umum, hasil uji normalitas, QQ Plot, dan analisis probabilitas menunjukkan bahwa karakteristik distribusi data berbeda untuk setiap variabel. Oleh karena itu, interpretasi hasil analisis statistik perlu mempertimbangkan asumsi distribusi data yang digunakan agar kesimpulan yang diperoleh lebih akurat.

3.6 Korelasi

Analisis korelasi Pearson digunakan untuk mengukur kekuatan dan arah hubungan linear antara dua variabel numerik Hair *et al.* (2019). Analisis korelasi merupakan metode statistik yang digunakan untuk mengetahui hubungan antar variabel dalam suatu dataset. Pada penelitian ini, analisis korelasi dilakukan menggunakan metode *Pearson* untuk mengukur kekuatan serta arah hubungan linear antar variabel pembangunan wilayah.

Variabel yang dianalisis meliputi *pdrb_perkapita*, *kemiskinan*, *pengangguran*, *ipm*, *harapan_hidup*, *rata_lama_sekolah*, dan *akses_internet*. Hasil analisis korelasi ditampilkan dalam bentuk ringkasan berikut.

Tabel 3.6 Hasil Analisis Korelasi

Variabel 1	Variabel 2	Nilai Korelasi	Keterangan
pdrb_perkapita	kemiskinan	-0,0048	Sangat lemah (negatif)
pengangguran	pdrb_perkapita	-0,0323	Sangat lemah (negatif)
ipm	pdrb_perkapita	0,0111	Sangat lemah (positif)
harapan_hidup	pdrb_perkapita	0,0125	Sangat lemah (positif)
akses_internet	kemiskinan	-0,0309	Sangat lemah (negatif)
akses_internet	ipm	0,0020	Sangat lemah (positif)

Berdasarkan hasil analisis, seluruh nilai korelasi berada sangat dekat dengan nol, yaitu dalam rentang sekitar -0,03 hingga 0,01. Hal ini menunjukkan bahwa hubungan linear antar variabel dalam dataset pembangunan wilayah sangat lemah.

Tidak adanya korelasi yang kuat mengindikasikan bahwa variabel-variabel tersebut tidak memiliki hubungan linear yang signifikan dan kemungkinan dipengaruhi oleh faktor lain di luar model yang digunakan.

3.7 Interpretasi

Berdasarkan seluruh hasil analisis yang telah dilakukan pada dataset pembangunan wilayah, dapat disimpulkan bahwa data memiliki karakteristik yang cukup beragam dengan tingkat penyebaran yang berbeda pada setiap variabel.

Pada analisis statistika deskriptif, variabel *pdrb_perkapita* menunjukkan nilai rata-rata yang tinggi dengan standar deviasi terbesar, yang mengindikasikan adanya ketimpangan ekonomi antar wilayah. Sementara itu, variabel *ipm*, *harapan_hidup*, dan *rata_lama_sekolah* memiliki penyebaran yang relatif kecil, sehingga dapat dikatakan lebih stabil dibandingkan variabel ekonomi.

Dari analisis *missing value*, diketahui bahwa proporsi data yang hilang relatif kecil, yaitu sekitar 1% pada setiap variabel. Oleh karena itu, metode penghapusan data dipilih karena tidak memberikan dampak signifikan terhadap representativitas data secara keseluruhan.

Selanjutnya, pada analisis *outlier*, ditemukan bahwa variabel *pdrb_perkapita*, *kemiskinan*, dan *pengangguran* memiliki nilai ekstrem. Keberadaan *outlier* ini terbukti mempengaruhi nilai rata-rata, terutama pada variabel *pdrb_perkapita* yang mengalami perubahan paling besar setelah penghapusan *outlier*. Hal ini menunjukkan adanya beberapa wilayah dengan kondisi ekonomi yang sangat berbeda dibandingkan wilayah lainnya.

Pada analisis distribusi data, terdapat indikasi bahwa beberapa variabel tidak berdistribusi normal, terutama variabel ekonomi. Hal ini sejalan dengan ditemukannya *outlier* serta perbedaan yang cukup besar antara nilai minimum dan maksimum.

Hasil analisis korelasi menunjukkan bahwa seluruh hubungan antar variabel memiliki nilai yang sangat kecil (mendekati nol), yaitu dalam rentang sekitar -0,03 hingga 0,01. Hal ini

menunjukkan bahwa tidak terdapat hubungan linear yang signifikan antar variabel, sehingga peningkatan pada satu indikator tidak secara langsung berkaitan dengan peningkatan indikator lainnya.

Secara keseluruhan, hasil analisis menunjukkan bahwa pembangunan wilayah merupakan fenomena yang kompleks dan tidak dapat dijelaskan hanya dengan hubungan linear sederhana. Terdapat ketimpangan pada beberapa indikator ekonomi, serta variasi antar wilayah yang cukup tinggi, sehingga diperlukan analisis lanjutan yang lebih mendalam untuk memahami faktor-faktor yang mempengaruhi pembangunan wilayah secara komprehensif.

BAB IV

KESIMPULAN

4.1 Kesimpulan Utama

Berdasarkan hasil analisis data pembangunan wilayah menggunakan bahasa pemrograman R, dapat disimpulkan bahwa dataset memiliki kualitas yang baik dengan tingkat *missing value* yang sangat rendah, yaitu sekitar 0,45% dari keseluruhan data. Penanganan *missing value* dilakukan dengan metode penghapusan karena proporsinya relatif kecil dan tidak memengaruhi representativitas data secara signifikan.

Analisis statistika deskriptif menunjukkan bahwa variabel ekonomi memiliki tingkat variasi yang lebih tinggi dibandingkan variabel pembangunan manusia. Selain itu, analisis *outlier* menunjukkan adanya beberapa data ekstrem pada variabel PDRB per kapita, kemiskinan, dan pengangguran.

Hasil analisis korelasi menunjukkan bahwa hubungan antar indikator pembangunan dalam dataset cenderung lemah dan tidak signifikan secara statistik. Dengan demikian, pembangunan wilayah merupakan fenomena yang kompleks dan dipengaruhi oleh berbagai faktor yang saling berkaitan.

4.2 Insight

1. Ketimpangan ekonomi antar wilayah masih terlihat dari adanya outlier pada variabel PDRB per kapita.
2. Variabel pembangunan manusia seperti IPM, harapan hidup, dan rata-rata lama sekolah memiliki distribusi yang relatif stabil.
3. Hubungan antar indikator pembangunan pada dataset tidak menunjukkan pola linear yang kuat.
4. Analisis pembangunan wilayah memerlukan pendekatan multivariat karena satu indikator tidak cukup menjelaskan kondisi pembangunan secara keseluruhan.

4.3 Saran

1. Menambahkan variabel lain seperti investasi daerah, tingkat urbanisasi, dan pengeluaran pemerintah agar analisis lebih komprehensif.
2. Melakukan analisis regresi atau machine learning untuk mengidentifikasi faktor yang paling berpengaruh terhadap pembangunan wilayah.
3. Melakukan visualisasi yang lebih mendalam menggunakan histogram, scatter plot, dan heatmap korelasi.
4. Memperbarui dataset secara berkala agar hasil analisis dapat mencerminkan kondisi pembangunan yang lebih aktual.

DAFTAR PUSTAKA

- Hair JF, Black WC, Babin BJ, Anderson RE. 2019. *Multivariate Data Analysis*. Cengage.
- James G, Witten D, Hastie T, Tibshirani R. 2021. *An Introduction to Statistical Learning*. Springer.
- Montgomery DC, Runger GC. 2018. *Applied Statistics and Probability for Engineers*. Wiley.
- Posit Software. 2024. *RStudio IDE User Guide*.
- Walpole RE, Myers RH, Myers SL, Ye K. 2018. *Probability and Statistics for Engineers and Scientists*. Pearson.
- Wickham H. 2016. *ggplot2: Elegant Graphics for Data Analysis*. Springer.

LAMPIRAN

5.1 Script R

```
# =====  
# 1.3.1 Memahami Dataset  
# =====  
data_pembangunan <-  
  ↪ read.csv("../dataset/pembangunan_wilayah_missing_outlier.csv")  
("--- STRUKTUR DATA ---")  
str(data_pembangunan)  
  
("--- 6 BARIS PERTAMA DATASET ---")  
head(data_pembangunan)  
  
("--- SUMMARY ---")  
summary(data_pembangunan)  
  
dimensi <- dim(data_pembangunan)  
cat("Jumlah Observasi (Baris) :", dimensi[1])  
cat("Jumlah Variabel (Kolom) :", dimensi[2])  
  
# =====  
# 1.3.2 Statistika Deskriptif  
# =====  
("--- Mengambil variabel numerik ---")  
data_numerik <- data_pembangunan[sapply(data_pembangunan, is.numeric)]  
  
("--- Ringkasan statistik deskriptif ---")
```

```

summary(data_numerik)

("--- Mean ---")
sapply(data_numerik, mean, na.rm = TRUE)

("--- Median ---")
sapply(data_numerik, median, na.rm = TRUE)

("--- Nilai minimum ---")
sapply(data_numerik, min, na.rm = TRUE)

("--- Nilai maksimum ---")
sapply(data_numerik, max, na.rm = TRUE)

("--- Standar deviasi ---")
sapply(data_numerik, sd, na.rm = TRUE)

("--- Varians ---")
sapply(data_numerik, var, na.rm = TRUE)

("--- Kuartil ---")
sapply(data_numerik, quantile, na.rm = TRUE)

# =====
# 1.3.3 Analisis Missing Value
# =====

("--- Memeriksa jumlah missing value di tiap variabel ---")
missing_value <- colSums(is.na(data_pembangunan))

```

```

("--- Merepresentasikan jumlah missing value tiap variabel ke dalam
  ↳ persentase ---")
percentage_missing_value <- missing_value / nrow(data_pembangunan) *
  ↳ 100

("--- Menghitung rata-rata persentase missing value dataframe (secara
  ↳ keseluruhan) ---")
percentage_missing_value_df <- mean(is.na(data_pembangunan)) * 100

("--- Melihat hasil perhitungan persentase ---")
print(ppercentage_missing_value_df)

("--- Karena persentase 0.4% < 30%, maka metode yang diambil adalah
  ↳ metode penghapusan ---")
data_pembangunan <- na.omit(data_pembangunan)

("--- Memeriksa kembali apakah jumlah baris dataset sudah diperbarui
  ↳ setelah penghapusan ---")
print(nrow(data_pembangunan))

# =====
# 1.3.4 Analisis Outlier
# =====

("--- Mengambil kolom variabel yang bertipe data numerik ---")
numeric_columns_name <-
  ↳ names(data_pembangunan)[sapply(data_pembangunan, is.numeric)]

```

```

outlier_columns <- c()

("--- Menghitung IQR tiap kolom numerik ---")
for(column_name in numeric_columns_name) {
  ("--- Mengambil kolom variabel yang bertipe data numerik ---")
  numeric_columns_name <-
  ↪ names(data_pembangunan)[sapply(data_pembangunan, is.numeric)]

  outlier_columns <- c()

  ("--- Menghitung IQR tiap kolom numerik ---")
  for(column_name in numeric_columns_name) {

    Q1 <- quantile(data_pembangunan[[column_name]], 0.25, na.rm = TRUE)
    Q3 <- quantile(data_pembangunan[[column_name]], 0.75, na.rm = TRUE)

    IQR <- Q3 - Q1

    lower_bound <- Q1 - 1.5 * IQR
    upper_bound <- Q3 + 1.5 * IQR

    outlier_values <- data_pembangunan[[column_name]][
      data_pembangunan[[column_name]] < lower_bound |
      data_pembangunan[[column_name]] > upper_bound
    ]

    total_outlier <- length(outlier_values)
  }
}

```

```

cat("\n===== \n")
cat("Variabel :", column_name, "\n")
cat("Jumlah Outlier :", total_outlier, "\n")

if(total_outlier > 0) {

  outlier_columns <- c(outlier_columns, column_name)

  cat("\nNilai Outlier:\n")
  print(outlier_values)

  mean_sebelum <- mean(
    data_pembangunan[[column_name]],
    na.rm = TRUE
  )

  data_tanpa_outlier <- data_pembangunan[[column_name]][
    data_pembangunan[[column_name]] >= lower_bound &
    data_pembangunan[[column_name]] <= upper_bound
  ]

  mean_setelah <- mean(
    data_tanpa_outlier,
    na.rm = TRUE
  )

  cat("\nRata-rata Outlier :", mean(outlier_values), "\n")
  cat("Mean Sebelum :", mean_sebelum, "\n")

```

```

    cat("Mean Setelah :", mean_setelah, "\n")
    cat("Selisih Mean :", abs(mean_sebelum - mean_setelah), "\n")
  }
}
}

("--- Membuat boxplot hanya untuk variabel yang memiliki outlier ---")
par(mfrow = c(1, length(outlier_columns)))

for(col in outlier_columns) {
  boxplot(
    data_pembangunan[[col]],
    main = col,
    ylab = col
  )
}

# Bagian : 1.3.5 Visualisasi Data
#           1.3.6 Analisis Probabilitas dan Distribusi Data

library(ggplot2)
data <- read.csv(
  "data/pembangunan_wilayah_missing_outlier.csv"
)

#bersihin Missing Value

```



```

data_clean <- na.omit(data)

cat("Jumlah data sebelum pembersihan :", nrow(data), "\n")
cat("Jumlah data setelah pembersihan :", nrow(data_clean), "\n")

# =====
# 1.3.5 VISUALISASI DATA
# =====

# Grafik 1 : Histogram IPM

ggplot(data_clean, aes(x = ipm)) +
  geom_histogram(binwidth = 3) +
  labs(
    title = "Distribusi Nilai IPM",
    x = "IPM",
    y = "Frekuensi"
  )

# Grafik 2 : Histogram Kemiskinan

ggplot(data_clean, aes(x = kemiskinan)) +
  geom_histogram(binwidth = 2) +
  labs(
    title = "Distribusi Tingkat Kemiskinan",
    x = "Kemiskinan (%)",
    y = "Frekuensi"
  )

```

Grafik 3 : Boxplot PDRB Per Kapita

```
ggplot(data_clean, aes(y = pdrb_perkapita)) +  
  geom_boxplot() +  
  labs(  
    title = "Boxplot PDRB Per Kapita",  
    y = "PDRB Per Kapita"  
  )
```

Grafik 4 : Scatter Plot Kemiskinan vs IPM

```
ggplot(data_clean,  
  aes(  
    x = kemiskinan,  
    y = ipm  
  )) +  
  geom_point() +  
  labs(  
    title = "Hubungan Kemiskinan dan IPM",  
    x = "Kemiskinan (%)",  
    y = "IPM"  
  )
```

*# Grafik 5 : Scatter Plot Akses Internet
vs Rata Lama Sekolah*

```
ggplot(data_clean,
```

```

    aes(
      x = akses_internet,
      y = rata_lama_sekolah
    ) +
  geom_point() +
  labs(
    title = "Hubungan Akses Internet dan Rata Lama Sekolah",
    x = "Akses Internet (%)",
    y = "Rata Lama Sekolah (Tahun)"
  )

# =====
# 1.3.6 ANALISIS DISTRIBUSI DATA
# =====

# Uji Normalitas Shapiro-Wilk

shapiro_ipm <- shapiro.test(data_clean$ipm)
shapiro_kemiskinan <- shapiro.test(data_clean$kemiskinan)
shapiro_internet <- shapiro.test(data_clean$akses_internet)

cat("\n")
cat("=====\n")
cat("HASIL UJI NORMALITAS\n")
cat("=====\n")

print(shapiro_ipm)
print(shapiro_kemiskinan)

```

```

print(shapiro_internet)

# QQ Plot IPM

qqnorm(data_clean$ipm,
        main = "QQ Plot IPM")
qqline(data_clean$ipm)

# QQ Plot Kemiskinan

qqnorm(data_clean$kemiskinan,
        main = "QQ Plot Kemiskinan")
qqline(data_clean$kemiskinan)

# =====
# ANALISIS PROBABILITAS
# =====

# Probabilitas Kemiskinan
# di atas rata-rata

mean_kemiskinan <- mean(data_clean$kemiskinan)

prob_kemiskinan_atas_rata <- mean(
  data_clean$kemiskinan > mean_kemiskinan
)

cat("\n")

```

```

cat("=====\n")
cat("PROBABILITAS KEMISKINAN\n")
cat("=====\n")

cat(
  "Probabilitas wilayah memiliki kemiskinan di atas rata-rata = ",
  round(prob_kemiskinan_atas_rata,4),
  "\n"
)

# Probabilitas IPM > 75

prob_ipm_tinggi <- mean(
  data_clean$ipm > 75
)

cat(
  "Probabilitas wilayah memiliki IPM > 75 = ",
  round(prob_ipm_tinggi,4),
  "\n"
)

# Probabilitas Normal pakai pnorm()
# P(IPM < 75)

prob_normal_ipm <- pnorm(
  75,
  mean(data_clean$ipm),

```

```

sd(data_clean$ipm)
)

cat(
  "Probabilitas IPM kurang dari 75 (Distribusi Normal) = ",
  round(prob_normal_ipm,4),
  "\n"
)

# Nilai IPM pada persentil ke-95
# pakai qnorm()

ipm_p95 <- qnorm(
  0.95,
  mean(data_clean$ipm),
  sd(data_clean$ipm)
)

cat(
  "Nilai IPM pada persentil ke-95 = ",
  round(ipm_p95,2),
  "\n"
)

# =====
# TABEL RINGKAS HASIL UJI NORMALITAS
# =====

```

```

hasil_normalitas <- data.frame(
  Variabel = c(
    "IPM",
    "Kemiskinan",
    "Akses Internet"
  ),
  P_Value = c(
    shapiro_ipm$p.value,
    shapiro_kemiskinan$p.value,
    shapiro_internet$p.value
  )
)

hasil_normalitas$Kesimpulan <-
  ifelse(
    hasil_normalitas$P_Value > 0.05,
    "Berdistribusi Normal",
    "Tidak Berdistribusi Normal"
  )

cat("\n")
cat("=====\n")
cat("TABEL HASIL UJI NORMALITAS\n")
cat("=====\n")

print(hasil_normalitas)

```

```

# =====
# 1.3.7 Analisis Korelasi
# =====

data_bersih <- data_pembangunan[complete.cases(data_pembangunan), ]
kolom_numerik_korelasi <- c("pdrb_perkapita", "kemiskinan",
  ↪ "pengangguran", "ipm",
                                "harapan_hidup", "rata_lama_sekolah",
                                ↪ "akses_internet",
                                "jalan_baik", "air_bersih")

matriks_numerik <- data_bersih[, kolom_numerik_korelasi]

cat("--- Menghitung korelasi antar variabel ---")
matriks_korelasi <- cor(matriks_numerik, method = "pearson")
print(round(matriks_korelasi, 3))

cat("--- UJI KORELASI: IPM vs KEMISKINAN ---")
uji_ipm_kemiskinan <- cor.test(data_bersih$ipm, data_bersih$kemiskinan)
print(uji_ipm_kemiskinan)

cat("--- UJI KORELASI: AKSES INTERNET vs RATA-LAMA SEKOLAH ---")
uji_internet_sekolah <- cor.test(data_bersih$akses_internet,
  ↪ data_bersih$rata_lama_sekolah)
print(uji_internet_sekolah)

cat("--- UJI KORELASI: PDRB PERKAPITA vs IPM (KESEJAHTERAAN) ---")
uji_pdrb_ipm <- cor.test(data_bersih$pdrb_perkapita, data_bersih$ipm)
print(uji_pdrb_ipm)

```


5.2 Output Tambahan

```
##          wilayah          provinsi          tahun      pdrb_perkapita
##      "character"      "character"      "integer"      "numeric"
##      kemiskinan      pengangguran          ipm      harapan_hidup
##      "numeric"      "numeric"      "numeric"      "numeric"
## rata_lama_sekolah      akses_internet      jalan_baik      air_bersih
##      "numeric"      "numeric"      "numeric"      "numeric"
##      catatan_data
##      "character"
```

```
##          wilayah          provinsi tahun pdrb_perkapita kemiskinan
## 1 Kabupaten/Kota_1      Jawa Barat  2022      38403994      19.69
## 2 Kabupaten/Kota_2      Jawa Timur  2022      165582092      9.68
## 3 Kabupaten/Kota_3 Kalimantan Timur  2020      26780948      4.13
## 4 Kabupaten/Kota_4      DKI Jakarta  2022      155034790      20.43
## 5 Kabupaten/Kota_5 Sulawesi Selatan  2023      198834591      14.39
## 6 Kabupaten/Kota_6      Jawa Timur  2020      145702606      17.14
##      pengangguran      ipm      harapan_hidup rata_lama_sekolah      akses_internet      jalan_baik
## 1          4.73 80.16          75.75          8.41          63.86          53.86
## 2          4.43 55.05          67.85          5.79          66.61          34.89
## 3          2.99 78.70          60.38          13.20          64.73          48.57
## 4          3.90 73.27          69.49          12.28          44.59          57.88
## 5          12.15 72.90          75.00          9.69          52.72          65.70
## 6          3.38 65.11          67.04          5.66          55.63          70.12
##      air_bersih catatan_data
## 1          43.11          Normal
```

## 2	58.93	Normal
## 3	90.27	Normal
## 4	86.16	Normal
## 5	90.84	Normal
## 6	60.17	Normal

##	wilayah	provinsi	tahun	pdrb_perkapita
##	Length:2500	Length:2500	Min. :2020	Min. :1.503e+07
##	Class :character	Class :character	1st Qu.:2021	1st Qu.:6.962e+07
##	Mode :character	Mode :character	Median :2022	Median :1.373e+08
##			Mean :2022	Mean :1.357e+08
##			3rd Qu.:2023	3rd Qu.:1.939e+08
##			Max. :2024	Max. :1.775e+09
##				NA's :25
##	kemiskinan	pengangguran	ipm	harapan_hidup
##	Min. : 2.01	Min. : 1.010	Min. :55.01	Min. :60.01
##	1st Qu.: 7.86	1st Qu.: 4.350	1st Qu.:62.52	1st Qu.:64.66
##	Median :13.72	Median : 8.230	Median :69.89	Median :69.30
##	Mean :13.72	Mean : 8.046	Mean :69.90	Mean :69.13
##	3rd Qu.:19.39	3rd Qu.:11.520	3rd Qu.:77.16	3rd Qu.:73.58
##	Max. :67.53	Max. :47.040	Max. :84.99	Max. :77.99
##	NA's :24	NA's :25	NA's :25	
##	rata_lama_sekolah	akses_internet	jalan_baik	air_bersih
##	Min. : 5.020	Min. : 0.01	Min. :30.01	Min. :40.03
##	1st Qu.: 7.327	1st Qu.:38.91	1st Qu.:47.40	1st Qu.:54.32
##	Median : 9.520	Median :58.09	Median :65.02	Median :69.68
##	Mean : 9.581	Mean :58.79	Mean :65.26	Mean :69.76
##	3rd Qu.:11.912	3rd Qu.:78.67	3rd Qu.:83.24	3rd Qu.:85.18
##	Max. :14.000	Max. :97.99	Max. :99.95	Max. :99.99

```

##          NA's      :25      NA's      :25
## catatan_data
## Length:2500
## Class :character
## Mode  :character
##
##
##
##

## Jumlah Observasi (Baris) : 2500

## Jumlah Variabel (Kolom)  : 13

##      tahun      pdrb_perkapita      kemiskinan      pengangguran
## Min.      :2020  Min.      :1.503e+07  Min.      : 2.01  Min.      : 1.010
## 1st Qu.:2021  1st Qu.:6.962e+07  1st Qu.: 7.86  1st Qu.: 4.350
## Median :2022  Median :1.373e+08  Median :13.72  Median : 8.230
## Mean      :2022  Mean      :1.357e+08  Mean      :13.72  Mean      : 8.046
## 3rd Qu.:2023  3rd Qu.:1.939e+08  3rd Qu.:19.39  3rd Qu.:11.520
## Max.      :2024  Max.      :1.775e+09  Max.      :67.53  Max.      :47.040
##          NA's      :25      NA's      :24      NA's      :25
##      ipm      harapan_hidup      rata_lama_sekolah      akses_internet
## Min.      :55.01  Min.      :60.01  Min.      : 5.020  Min.      : 0.01
## 1st Qu.:62.52  1st Qu.:64.66  1st Qu.: 7.327  1st Qu.:38.91
## Median :69.89  Median :69.30  Median : 9.520  Median :58.09
## Mean      :69.90  Mean      :69.13  Mean      : 9.581  Mean      :58.79
## 3rd Qu.:77.16  3rd Qu.:73.58  3rd Qu.:11.912  3rd Qu.:78.67
## Max.      :84.99  Max.      :77.99  Max.      :14.000  Max.      :97.99
## NA's      :25          NA's      :25

```

```
##      jalan_baik      air_bersih
## Min.      :30.01   Min.      :40.03
## 1st Qu.:47.40   1st Qu.:54.32
## Median :65.02   Median :69.68
## Mean      :65.26   Mean      :69.76
## 3rd Qu.:83.24   3rd Qu.:85.18
## Max.      :99.95   Max.      :99.99
## NA's      :25
```

```
##          tahun      pdrb_perkapita      kemiskinan      pengangguran
## 2.021999e+03      1.356505e+08      1.372146e+01      8.045733e+00
##          ipm      harapan_hidup rata_lama_sekolah      akses_internet
## 6.989999e+01      6.913015e+01      9.580684e+00      5.878903e+01
##      jalan_baik      air_bersih
## 6.525808e+01      6.976153e+01
```

```
##          tahun      pdrb_perkapita      kemiskinan      pengangguran
## 2.022000e+03      1.373106e+08      1.372000e+01      8.230000e+00
##          ipm      harapan_hidup rata_lama_sekolah      akses_internet
## 6.989000e+01      6.929500e+01      9.520000e+00      5.809000e+01
##      jalan_baik      air_bersih
## 6.502000e+01      6.968000e+01
```

```
##          tahun      pdrb_perkapita      kemiskinan      pengangguran
## 2020.00      15031581.00      2.01      1.01
##          ipm      harapan_hidup rata_lama_sekolah      akses_internet
## 55.01      60.01      5.02      0.01
##      jalan_baik      air_bersih
## 30.01      40.03
```

##	tahun	pdrb_perkapita	kemiskinan	pengangguran
##	2.024000e+03	1.774545e+09	6.753000e+01	4.704000e+01
##	ipm	harapan_hidup	rata_lama_sekolah	akses_internet
##	8.499000e+01	7.799000e+01	1.400000e+01	9.799000e+01
##	jalan_baik	air_bersih		
##	9.995000e+01	9.999000e+01		

##	tahun	pdrb_perkapita	kemiskinan	pengangguran
##	1.431789e+00	8.934127e+07	6.894704e+00	4.258576e+00
##	ipm	harapan_hidup	rata_lama_sekolah	akses_internet
##	8.535062e+00	5.171779e+00	2.627008e+00	2.282030e+01
##	jalan_baik	air_bersih		
##	2.036569e+01	1.749921e+01		

##	tahun	pdrb_perkapita	kemiskinan	pengangguran
##	2.050019e+00	7.981863e+15	4.753694e+01	1.813547e+01
##	ipm	harapan_hidup	rata_lama_sekolah	akses_internet
##	7.284728e+01	2.674730e+01	6.901173e+00	5.207660e+02
##	jalan_baik	air_bersih		
##	4.147613e+02	3.062222e+02		

##	tahun	pdrb_perkapita	kemiskinan	pengangguran	ipm	harapan_hidup
## 0%	2020	15031581	2.0100	1.01	55.01	60.0100
## 25%	2021	69622210	7.8600	4.35	62.52	64.6575
## 50%	2022	137310624	13.7200	8.23	69.89	69.2950
## 75%	2023	193899157	19.3925	11.52	77.16	73.5850
## 100%	2024	1774545027	67.5300	47.04	84.99	77.9900
##	rata_lama_sekolah	akses_internet	jalan_baik	air_bersih		
## 0%		5.0200	0.010	30.010	40.0300	
## 25%		7.3275	38.915	47.395	54.3175	

```

## 50%          9.5200          58.090          65.020          69.6800
## 75%          11.9125         78.670          83.240          85.1825
## 100%         14.0000         97.990          99.950          99.9900

## [1] 0.4584615

## [1] 2357

## [1] "--- Mengambil kolom variabel yang bertipe data numerik ---"

## [1] "--- Menghitung IQR tiap kolom numerik ---"

##
## =====
## Variabel : tahun
## Jumlah Outlier : 0
##
## =====
## Variabel : pdrb_perkapita
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 1472419961 1474832345 1774545027 1087231959 1012449971
##
## Rata-rata Outlier : 1364295853
## Mean Sebelum : 135736399
## Mean Setelah : 133124666
## Selisih Mean : 2611734
##
## =====

```

```

## Variabel : kemiskinan
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 45.95 53.30 67.53 47.69 58.41
##
## Rata-rata Outlier : 54.576
## Mean Sebelum : 13.68089
## Mean Setelah : 13.59395
## Selisih Mean : 0.08693689
##
## =====
## Variabel : pengangguran
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 47.04 34.90 36.74 36.68 33.19
##
## Rata-rata Outlier : 37.71
## Mean Sebelum : 8.053271
## Mean Setelah : 7.990225
## Selisih Mean : 0.06304577
##
## =====
## Variabel : ipm
## Jumlah Outlier : 0
##
## =====
## Variabel : harapan_hidup

```

```

## Jumlah Outlier : 0
##
## =====
## Variabel : rata_lama_sekolah
## Jumlah Outlier : 0
##
## =====
## Variabel : akses_internet
## Jumlah Outlier : 0
##
## =====
## Variabel : jalan_baik
## Jumlah Outlier : 0
##
## =====
## Variabel : air_bersih
## Jumlah Outlier : 0
##
## =====
## Variabel : tahun
## Jumlah Outlier : 0
##
## =====
## Variabel : pdrb_perkapita
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 1472419961 1474832345 1774545027 1087231959 1012449971
##

```



```

## Rata-rata Outlier : 1364295853
## Mean Sebelum : 135736399
## Mean Setelah : 133124666
## Selisih Mean : 2611734
##
## =====
## Variabel : kemiskinan
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 45.95 53.30 67.53 47.69 58.41
##
## Rata-rata Outlier : 54.576
## Mean Sebelum : 13.68089
## Mean Setelah : 13.59395
## Selisih Mean : 0.08693689
##
## =====
## Variabel : pengangguran
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 47.04 34.90 36.74 36.68 33.19
##
## Rata-rata Outlier : 37.71
## Mean Sebelum : 8.053271
## Mean Setelah : 7.990225
## Selisih Mean : 0.06304577
##

```

```

## =====
## Variabel : ipm
## Jumlah Outlier : 0
##
## =====
## Variabel : harapan_hidup
## Jumlah Outlier : 0
##
## =====
## Variabel : rata_lama_sekolah
## Jumlah Outlier : 0
##
## =====
## Variabel : akses_internet
## Jumlah Outlier : 0
##
## =====
## Variabel : jalan_baik
## Jumlah Outlier : 0
##
## =====
## Variabel : air_bersih
## Jumlah Outlier : 0
##
## =====
## Variabel : tahun
## Jumlah Outlier : 0
##
## =====

```

```

## Variabel : pdrb_perkapita
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 1472419961 1474832345 1774545027 1087231959 1012449971
##
## Rata-rata Outlier : 1364295853
## Mean Sebelum : 135736399
## Mean Setelah : 133124666
## Selisih Mean : 2611734
##
## =====
## Variabel : kemiskinan
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 45.95 53.30 67.53 47.69 58.41
##
## Rata-rata Outlier : 54.576
## Mean Sebelum : 13.68089
## Mean Setelah : 13.59395
## Selisih Mean : 0.08693689
##
## =====
## Variabel : pengangguran
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 47.04 34.90 36.74 36.68 33.19

```

```

##
## Rata-rata Outlier : 37.71
## Mean Sebelum : 8.053271
## Mean Setelah : 7.990225
## Selisih Mean : 0.06304577
##
## =====
## Variabel : ipm
## Jumlah Outlier : 0
##
## =====
## Variabel : harapan_hidup
## Jumlah Outlier : 0
##
## =====
## Variabel : rata_lama_sekolah
## Jumlah Outlier : 0
##
## =====
## Variabel : akses_internet
## Jumlah Outlier : 0
##
## =====
## Variabel : jalan_baik
## Jumlah Outlier : 0
##
## =====
## Variabel : air_bersih
## Jumlah Outlier : 0

```

```

##
## =====
## Variabel : tahun
## Jumlah Outlier : 0
##
## =====
## Variabel : pdrb_perkapita
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 1472419961 1474832345 1774545027 1087231959 1012449971
##
## Rata-rata Outlier : 1364295853
## Mean Sebelum : 135736399
## Mean Setelah : 133124666
## Selisih Mean : 2611734
##
## =====
## Variabel : kemiskinan
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 45.95 53.30 67.53 47.69 58.41
##
## Rata-rata Outlier : 54.576
## Mean Sebelum : 13.68089
## Mean Setelah : 13.59395
## Selisih Mean : 0.08693689
##

```

```

## =====
## Variabel : pengangguran
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 47.04 34.90 36.74 36.68 33.19
##
## Rata-rata Outlier : 37.71
## Mean Sebelum : 8.053271
## Mean Setelah : 7.990225
## Selisih Mean : 0.06304577
##
## =====
## Variabel : ipm
## Jumlah Outlier : 0
##
## =====
## Variabel : harapan_hidup
## Jumlah Outlier : 0
##
## =====
## Variabel : rata_lama_sekolah
## Jumlah Outlier : 0
##
## =====
## Variabel : akses_internet
## Jumlah Outlier : 0
##
## =====

```

```

## Variabel : jalan_baik
## Jumlah Outlier : 0
##
## =====
## Variabel : air_bersih
## Jumlah Outlier : 0
##
## =====
## Variabel : tahun
## Jumlah Outlier : 0
##
## =====
## Variabel : pdrb_perkapita
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 1472419961 1474832345 1774545027 1087231959 1012449971
##
## Rata-rata Outlier : 1364295853
## Mean Sebelum : 135736399
## Mean Setelah : 133124666
## Selisih Mean : 2611734
##
## =====
## Variabel : kemiskinan
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 45.95 53.30 67.53 47.69 58.41

```

```

##
## Rata-rata Outlier : 54.576
## Mean Sebelum : 13.68089
## Mean Setelah : 13.59395
## Selisih Mean : 0.08693689
##
## =====
## Variabel : pengangguran
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 47.04 34.90 36.74 36.68 33.19
##
## Rata-rata Outlier : 37.71
## Mean Sebelum : 8.053271
## Mean Setelah : 7.990225
## Selisih Mean : 0.06304577
##
## =====
## Variabel : ipm
## Jumlah Outlier : 0
##
## =====
## Variabel : harapan_hidup
## Jumlah Outlier : 0
##
## =====
## Variabel : rata_lama_sekolah
## Jumlah Outlier : 0

```



```

##
## =====
## Variabel : akses_internet
## Jumlah Outlier : 0
##
## =====
## Variabel : jalan_baik
## Jumlah Outlier : 0
##
## =====
## Variabel : air_bersih
## Jumlah Outlier : 0
##
## =====
## Variabel : tahun
## Jumlah Outlier : 0
##
## =====
## Variabel : pdrb_perkapita
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 1472419961 1474832345 1774545027 1087231959 1012449971
##
## Rata-rata Outlier : 1364295853
## Mean Sebelum : 135736399
## Mean Setelah : 133124666
## Selisih Mean : 2611734
##

```

```

## =====
## Variabel : kemiskinan
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 45.95 53.30 67.53 47.69 58.41
##
## Rata-rata Outlier : 54.576
## Mean Sebelum : 13.68089
## Mean Setelah : 13.59395
## Selisih Mean : 0.08693689
##
## =====
## Variabel : pengangguran
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 47.04 34.90 36.74 36.68 33.19
##
## Rata-rata Outlier : 37.71
## Mean Sebelum : 8.053271
## Mean Setelah : 7.990225
## Selisih Mean : 0.06304577
##
## =====
## Variabel : ipm
## Jumlah Outlier : 0
##
## =====

```

```

## Variabel : harapan_hidup
## Jumlah Outlier : 0
##
## =====
## Variabel : rata_lama_sekolah
## Jumlah Outlier : 0
##
## =====
## Variabel : akses_internet
## Jumlah Outlier : 0
##
## =====
## Variabel : jalan_baik
## Jumlah Outlier : 0
##
## =====
## Variabel : air_bersih
## Jumlah Outlier : 0
##
## =====
## Variabel : tahun
## Jumlah Outlier : 0
##
## =====
## Variabel : pdrb_perkapita
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 1472419961 1474832345 1774545027 1087231959 1012449971

```

```

##
## Rata-rata Outlier : 1364295853
## Mean Sebelum : 135736399
## Mean Setelah : 133124666
## Selisih Mean : 2611734
##
## =====
## Variabel : kemiskinan
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 45.95 53.30 67.53 47.69 58.41
##
## Rata-rata Outlier : 54.576
## Mean Sebelum : 13.68089
## Mean Setelah : 13.59395
## Selisih Mean : 0.08693689
##
## =====
## Variabel : pengangguran
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 47.04 34.90 36.74 36.68 33.19
##
## Rata-rata Outlier : 37.71
## Mean Sebelum : 8.053271
## Mean Setelah : 7.990225
## Selisih Mean : 0.06304577

```

```

##
## =====
## Variabel : ipm
## Jumlah Outlier : 0
##
## =====
## Variabel : harapan_hidup
## Jumlah Outlier : 0
##
## =====
## Variabel : rata_lama_sekolah
## Jumlah Outlier : 0
##
## =====
## Variabel : akses_internet
## Jumlah Outlier : 0
##
## =====
## Variabel : jalan_baik
## Jumlah Outlier : 0
##
## =====
## Variabel : air_bersih
## Jumlah Outlier : 0
##
## =====
## Variabel : tahun
## Jumlah Outlier : 0
##

```

```

## =====
## Variabel : pdrb_perkapita
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 1472419961 1474832345 1774545027 1087231959 1012449971
##
## Rata-rata Outlier : 1364295853
## Mean Sebelum : 135736399
## Mean Setelah : 133124666
## Selisih Mean : 2611734
##
## =====
## Variabel : kemiskinan
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 45.95 53.30 67.53 47.69 58.41
##
## Rata-rata Outlier : 54.576
## Mean Sebelum : 13.68089
## Mean Setelah : 13.59395
## Selisih Mean : 0.08693689
##
## =====
## Variabel : pengangguran
## Jumlah Outlier : 5
##
## Nilai Outlier:

```

```

## [1] 47.04 34.90 36.74 36.68 33.19
##
## Rata-rata Outlier : 37.71
## Mean Sebelum : 8.053271
## Mean Setelah : 7.990225
## Selisih Mean : 0.06304577
##
## =====
## Variabel : ipm
## Jumlah Outlier : 0
##
## =====
## Variabel : harapan_hidup
## Jumlah Outlier : 0
##
## =====
## Variabel : rata_lama_sekolah
## Jumlah Outlier : 0
##
## =====
## Variabel : akses_internet
## Jumlah Outlier : 0
##
## =====
## Variabel : jalan_baik
## Jumlah Outlier : 0
##
## =====
## Variabel : air_bersih

```

```

## Jumlah Outlier : 0
##
## =====
## Variabel : tahun
## Jumlah Outlier : 0
##
## =====
## Variabel : pdrb_perkapita
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 1472419961 1474832345 1774545027 1087231959 1012449971
##
## Rata-rata Outlier : 1364295853
## Mean Sebelum : 135736399
## Mean Setelah : 133124666
## Selisih Mean : 2611734
##
## =====
## Variabel : kemiskinan
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 45.95 53.30 67.53 47.69 58.41
##
## Rata-rata Outlier : 54.576
## Mean Sebelum : 13.68089
## Mean Setelah : 13.59395
## Selisih Mean : 0.08693689

```



```

##
## =====
## Variabel : pengangguran
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 47.04 34.90 36.74 36.68 33.19
##
## Rata-rata Outlier : 37.71
## Mean Sebelum : 8.053271
## Mean Setelah : 7.990225
## Selisih Mean : 0.06304577
##
## =====
## Variabel : ipm
## Jumlah Outlier : 0
##
## =====
## Variabel : harapan_hidup
## Jumlah Outlier : 0
##
## =====
## Variabel : rata_lama_sekolah
## Jumlah Outlier : 0
##
## =====
## Variabel : akses_internet
## Jumlah Outlier : 0
##

```

```

## =====
## Variabel : jalan_baik
## Jumlah Outlier : 0
##
## =====
## Variabel : air_bersih
## Jumlah Outlier : 0
##
## =====
## Variabel : tahun
## Jumlah Outlier : 0
##
## =====
## Variabel : pdrb_perkapita
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 1472419961 1474832345 1774545027 1087231959 1012449971
##
## Rata-rata Outlier : 1364295853
## Mean Sebelum : 135736399
## Mean Setelah : 133124666
## Selisih Mean : 2611734
##
## =====
## Variabel : kemiskinan
## Jumlah Outlier : 5
##
## Nilai Outlier:

```

```

## [1] 45.95 53.30 67.53 47.69 58.41
##
## Rata-rata Outlier : 54.576
## Mean Sebelum : 13.68089
## Mean Setelah : 13.59395
## Selisih Mean : 0.08693689
##
## =====
## Variabel : pengangguran
## Jumlah Outlier : 5
##
## Nilai Outlier:
## [1] 47.04 34.90 36.74 36.68 33.19
##
## Rata-rata Outlier : 37.71
## Mean Sebelum : 8.053271
## Mean Setelah : 7.990225
## Selisih Mean : 0.06304577
##
## =====
## Variabel : ipm
## Jumlah Outlier : 0
##
## =====
## Variabel : harapan_hidup
## Jumlah Outlier : 0
##
## =====
## Variabel : rata_lama_sekolah


```

```

## Jumlah Outlier : 0
##
## =====
## Variabel : akses_internet
## Jumlah Outlier : 0
##
## =====
## Variabel : jalan_baik
## Jumlah Outlier : 0
##
## =====
## Variabel : air_bersih
## Jumlah Outlier : 0

## [1] "--- Membuat boxplot hanya untuk variabel yang memiliki outlier ---"


```




```
## Jumlah data sebelum pembersihan : 2500
```

```
## Jumlah data setelah pembersihan : 2357
```


Distribusi Nilai IPM




Distribusi Tingkat Kemiskinan




Boxplot PDRB Per Kapita



Hubungan Kemiskinan dan IPM



Hubungan Akses Internet dan Rata Lama Sekolah



```
## =====
```

```
## HASIL UJI NORMALITAS
```

```
## =====
```

```
##
```

```
## Shapiro-Wilk normality test
```

```
##
```

```
## data: data_clean$ipm
```

```
## W = 0.95873, p-value < 2.2e-16
```

```
##
```

```
## Shapiro-Wilk normality test
```



```
##
## data: data_clean$kemiskinan
## W = 0.9425, p-value < 2.2e-16

##
## Shapiro-Wilk normality test
##
## data: data_clean$akses_internet
## W = 0.9566, p-value < 2.2e-16

## Probabilitas wilayah memiliki kemiskinan di atas rata-rata = 0.4968

## Probabilitas wilayah memiliki IPM > 75 = 0.3275

## Probabilitas IPM kurang dari 75 (Distribusi Normal) = 0.7204

## Nilai IPM pada persentil ke-95 = 84.06
```

##	Variabel	P_Value	Kesimpulan
## 1	IPM	2.379285e-25	Tidak Berdistribusi Normal
## 2	Kemiskinan	2.377348e-29	Tidak Berdistribusi Normal
## 3	Akses Internet	6.137887e-26	Tidak Berdistribusi Normal

##	pdrb_perkapita	kemiskinan	pengangguran	ipm	harapan_hidup
## pdrb_perkapita	1.000	-0.002	-0.028	0.009	0.011
## kemiskinan	-0.002	1.000	-0.011	0.019	-0.009
## pengangguran	-0.028	-0.011	1.000	0.001	0.004
## ipm	0.009	0.019	0.001	1.000	0.020
## harapan_hidup	0.011	-0.009	0.004	0.020	1.000
## rata_lama_sekolah	-0.002	0.010	0.008	0.018	-0.013

## akses_internet	-0.008	-0.032	0.027	-0.001	0.004
## jalan_baik	0.040	0.020	-0.005	0.025	0.000
## air_bersih	-0.005	0.009	0.008	0.025	-0.025
##	rata_lama_sekolah	akses_internet	jalan_baik	air_bersih	
## pdrb_perkapita	-0.002	-0.008	0.040	-0.005	
## kemiskinan	0.010	-0.032	0.020	0.009	
## pengangguran	0.008	0.027	-0.005	0.008	
## ipm	0.018	-0.001	0.025	0.025	
## harapan_hidup	-0.013	0.004	0.000	-0.025	
## rata_lama_sekolah	1.000	-0.014	0.052	0.019	
## akses_internet	-0.014	1.000	-0.004	-0.007	
## jalan_baik	0.052	-0.004	1.000	0.022	
## air_bersih	0.019	-0.007	0.022	1.000	

##

Pearson's product-moment correlation

##

data: data_bersih\$ipm and data_bersih\$kemiskinan

t = 0.91114, df = 2355, p-value = 0.3623

alternative hypothesis: true correlation is not equal to 0

95 percent confidence interval:

-0.02161901 0.05910187

sample estimates:

cor

0.01877202

##

Pearson's product-moment correlation

##

```

## data:  data_bersih$akses_internet and data_bersih$rata_lama_sekolah
## t = -0.68127, df = 2355, p-value = 0.4958
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.05438095  0.02635246
## sample estimates:
##          cor
## -0.01403712

##
## Pearson's product-moment correlation
##
## data:  data_bersih$pdrrb_perkapita and data_bersih$ipm
## t = 0.43587, df = 2355, p-value = 0.663
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.03140471  0.04933808
## sample estimates:
##          cor
## 0.008981327

```

